

TECHNOLOGIES IN EDUCATION
UNIVERSITY^{NSU}
MICROELECTRONICS
INNOVATIONS
CATALYTIC MATERIALS
ASSEMBLY POINT
SCIENTIFIC LABORATORY
HYBRID MATERIALS
GEOPHYSICS
ENGINEERING
ENERGY CONSERVATION
BIOTECHNOLOGY
GEOCHEMISTRY
NANOTECHNOLOGY
HIGH ENERGIES
SEMIOTICS
SCIENCE
MATHEMATICAL MODELING
IT DEEP LEARNING BRAIN STUDY COGNITIVE TECHNOLOGIES
ASTROPHYSICS BIOINFORMATICS
LASER PHYSICS
GLOBAL PRIORITY
KNOWLEDGE ECONOMY
GEOLOGY
ARCHEOLOGY
MATHEMATICAL MODELING

Базовые методы ИИ

Семинар 1

Глушенко Андрей Валерьевич
ФФ НГУ

Обзор курса

- Github: <https://github.com/andreymarlin/ml-phph>
- Email: a.glushenko@g.nsu.ru
- Telegram: @gsswgg
- Форма аттестации – диф. зачёт по следующим критериям:
 - Посещаемость
 - 5-минутки
 - Выполнение лабораторных работ
 - Поточная контрольная работа
 - Проект

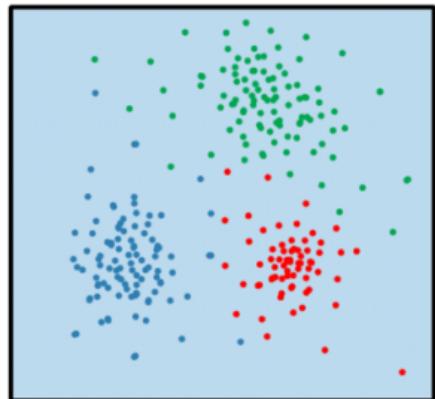
Что такое машинное обучение?



Типы машинного обучения

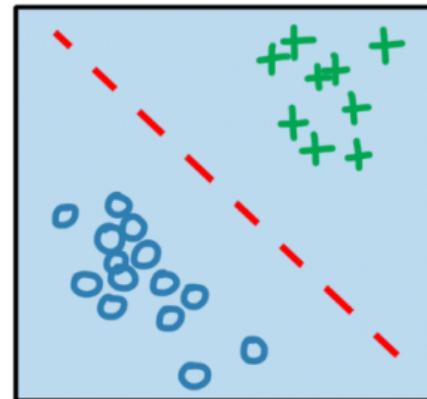
machine learning

Обучение без учителя
(Unsupervised learning)



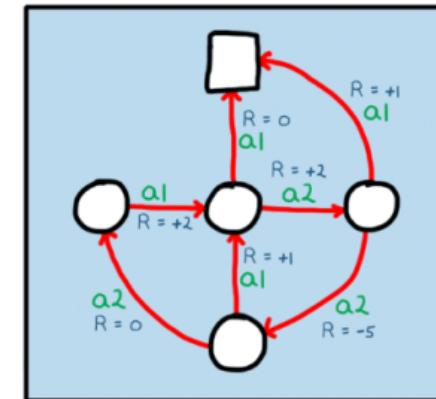
Неразмеченные данные
Нет обратной связи
Найти скрытую структуру

Обучение с учителем
(Supervised learning)



Размеченные данные
Предсказание
следующего значения

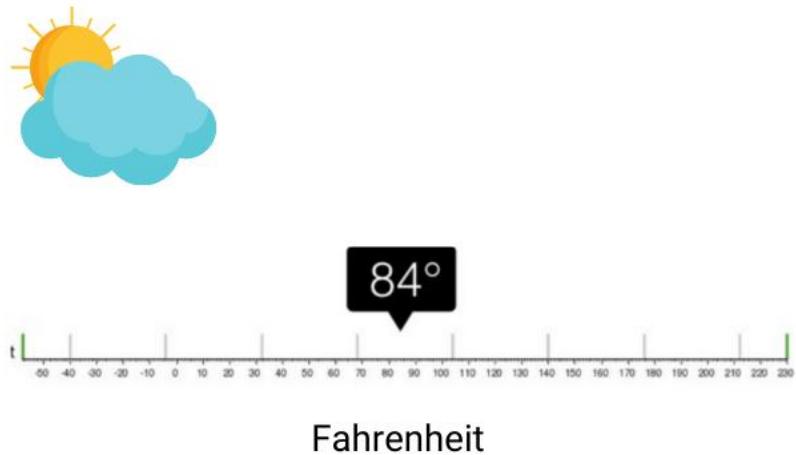
Обучение с подкреплением
(Reinforcement learning)



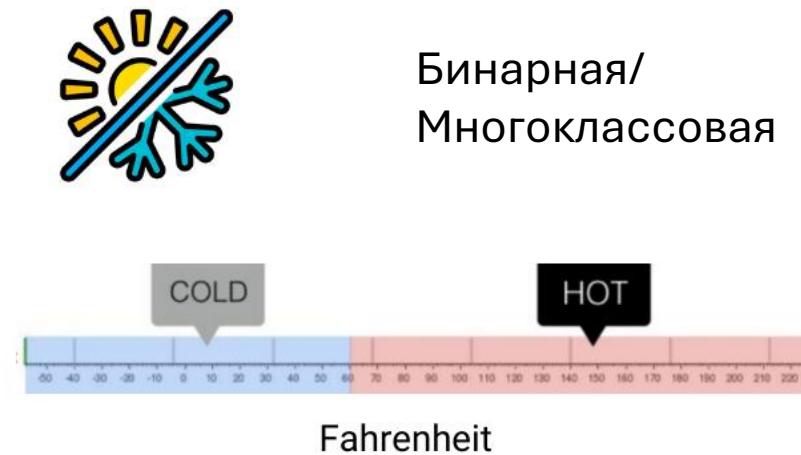
Принятие оптимальных решений
Взаимодействие со средой
Вознаграждения (или наказания) за результат

Задачи обучения с учителем

Регрессия (Regression)

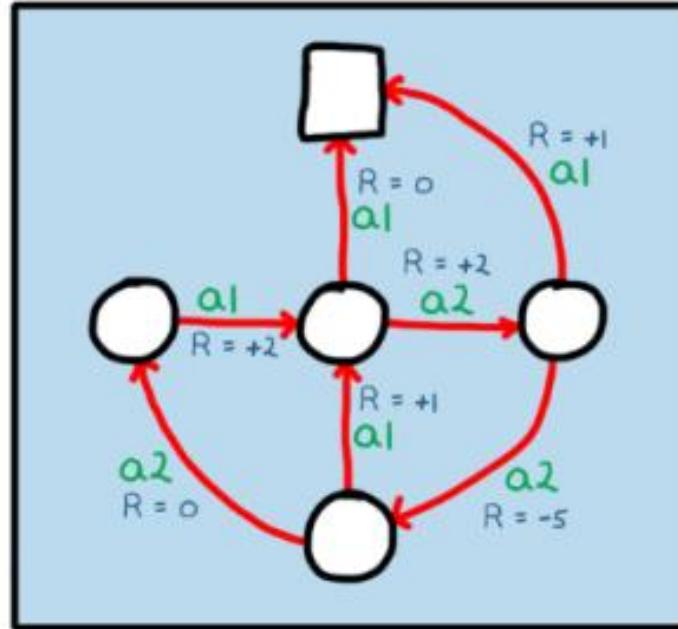


Классификация (Classification)



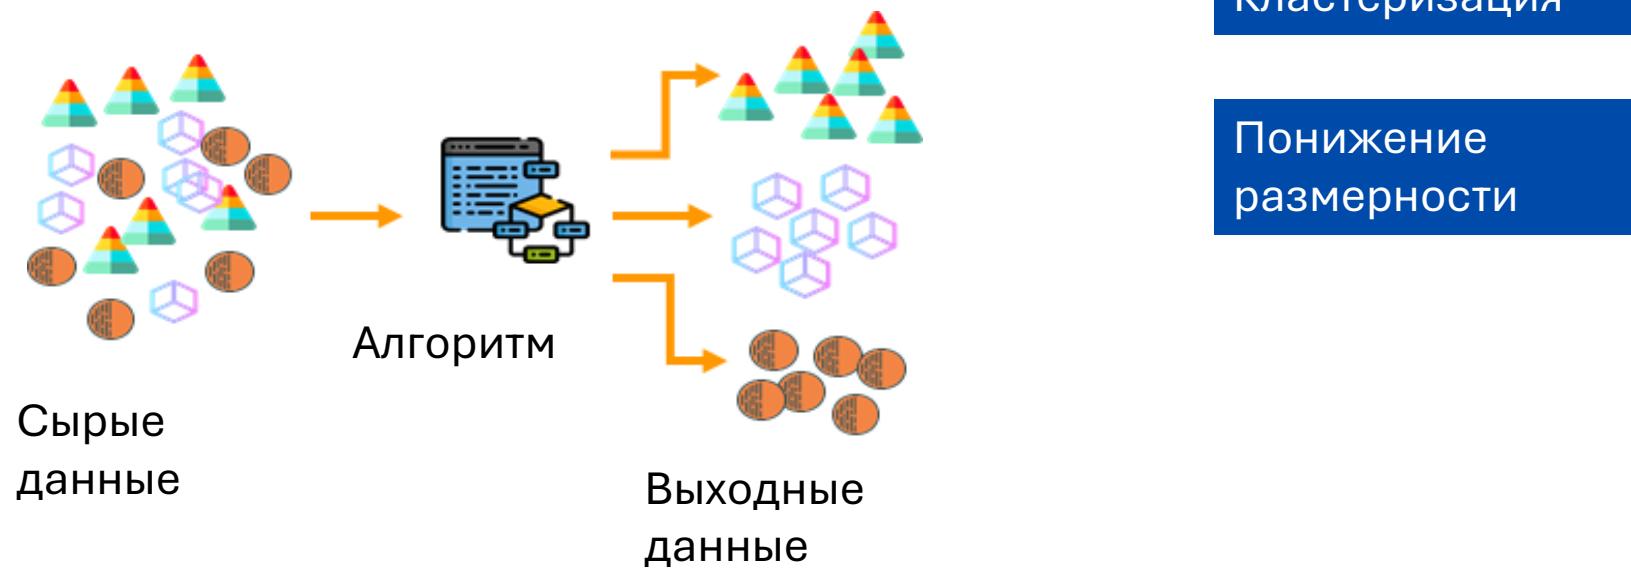
Source: <https://www.enjoyalgorithms.com/blogs/classification-and-regression-in-machine-learning>

Обучение с подкреплением (Reinforcement learning)



Принятие оптимальных решений
Взаимодействие со средой
Вознаграждения (или наказания) за результат

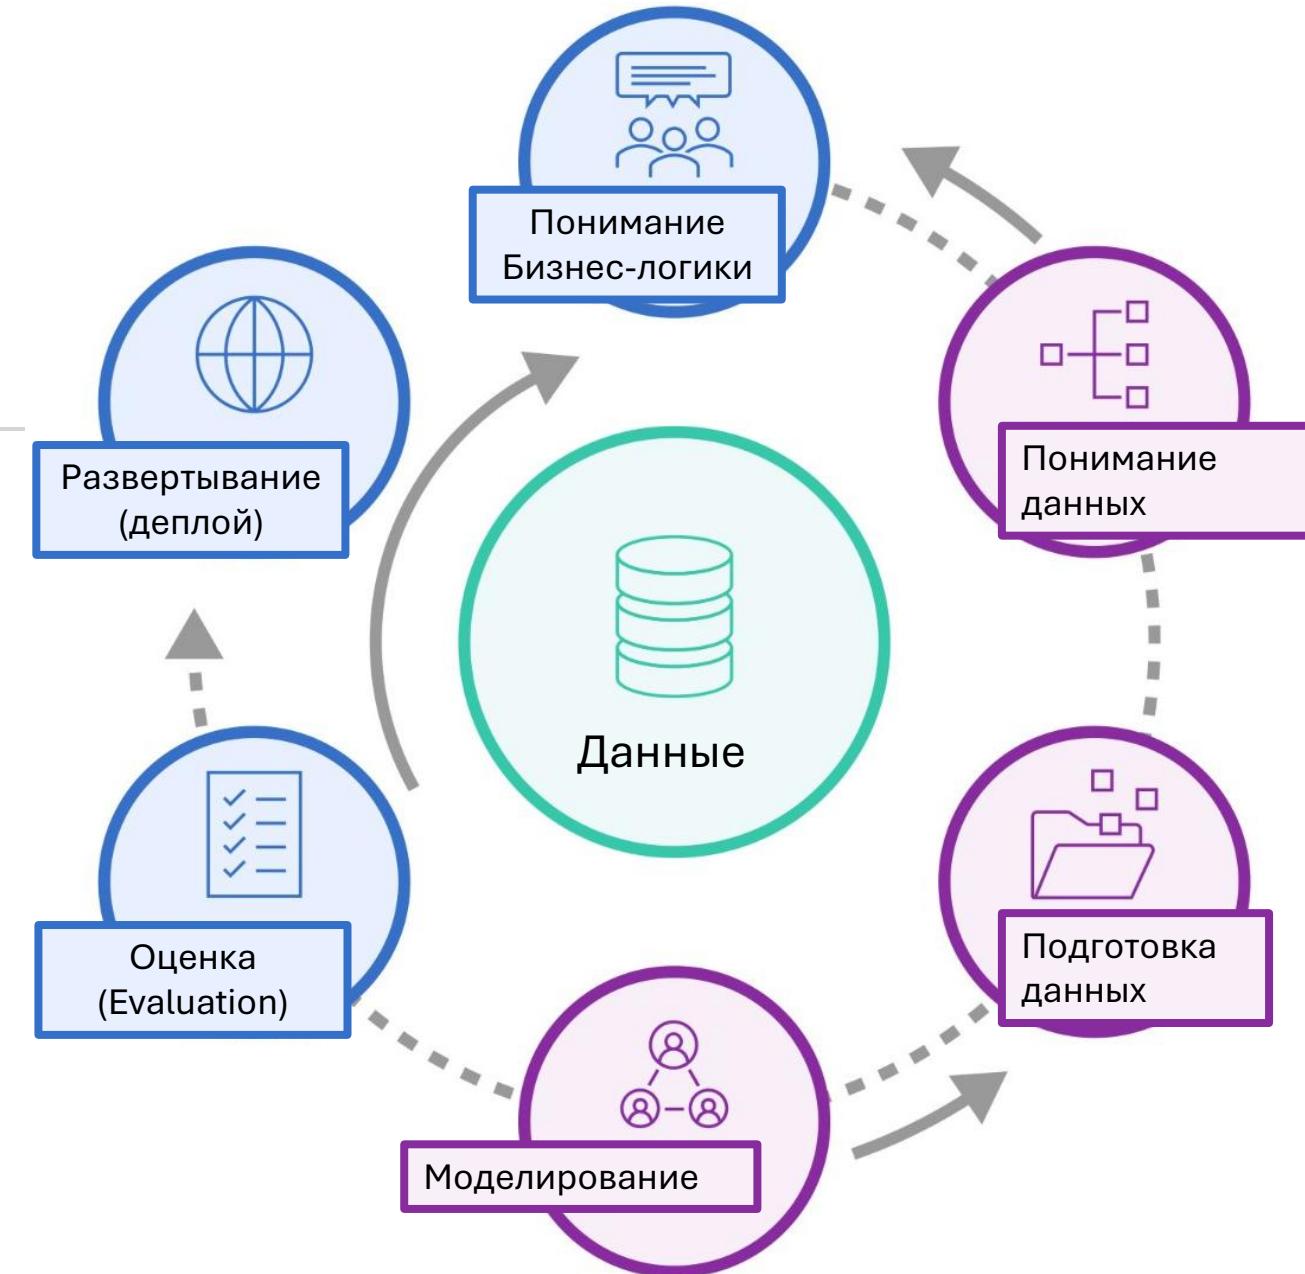
Задачи обучения без учителя



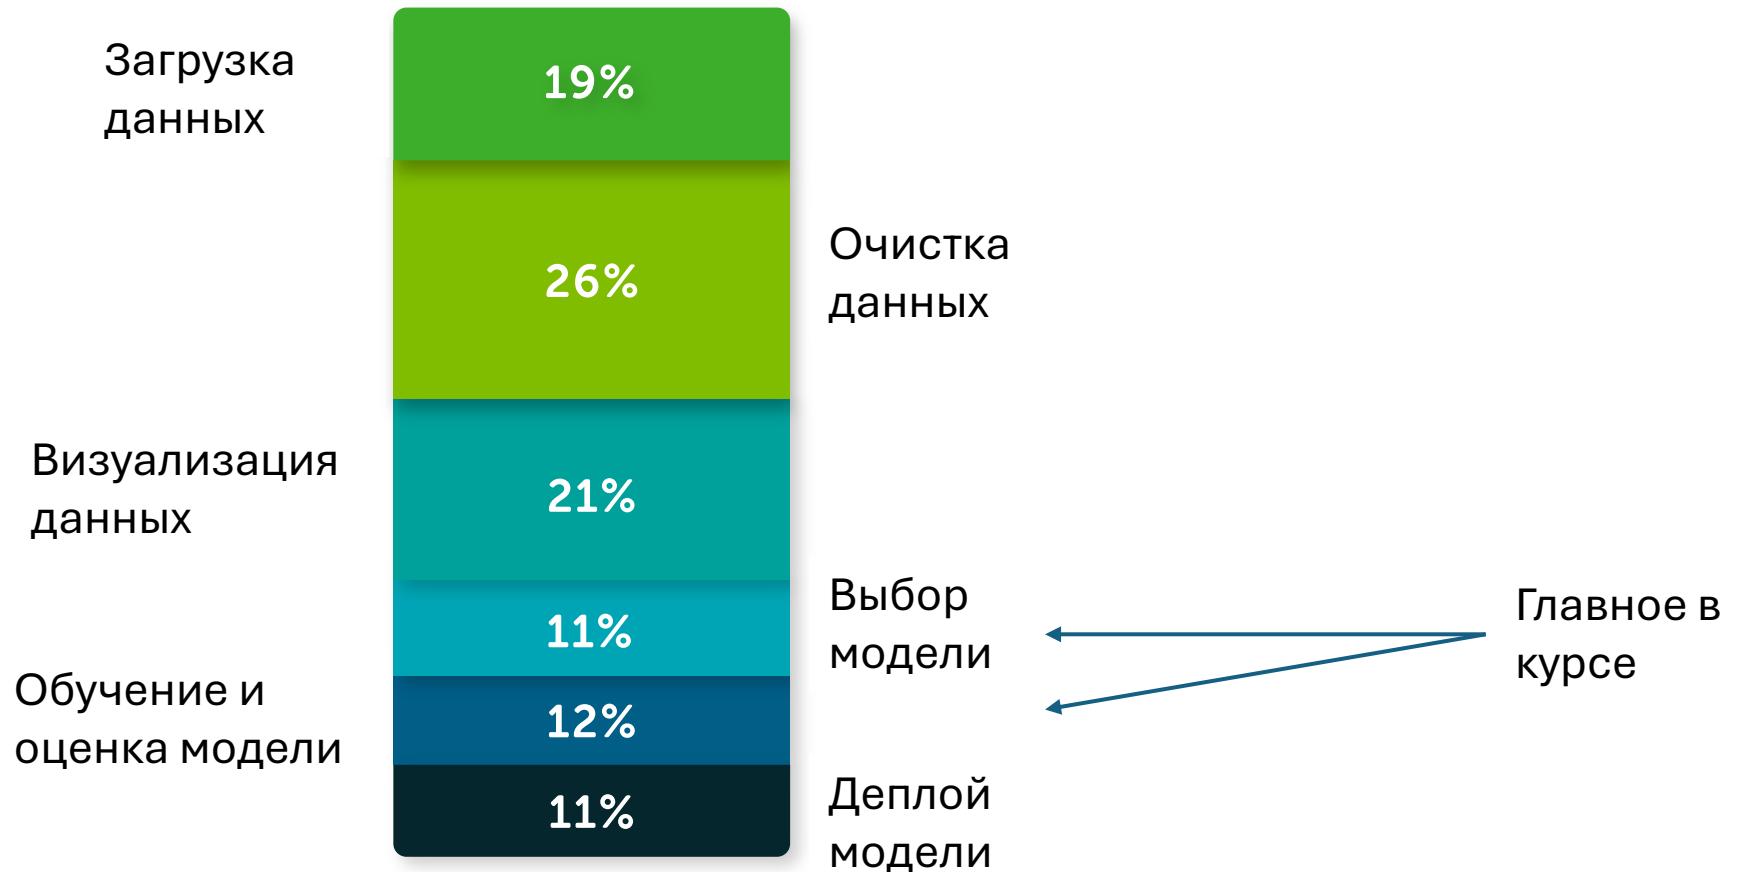
Source: <https://medium.com/analytics-vidhya/beginners-guide-to-unsupervised-learning-76a575c4e942>

Цикл жизни дата-майнинга

Cross-Industry Standard Process for Data Mining (CRISP-DM)



Затраты для выполнения задач ML



Source: <https://www.anaconda.com/resources/whitepapers/state-of-data-science-2020>

Компоненты пайплайна машинного обучения

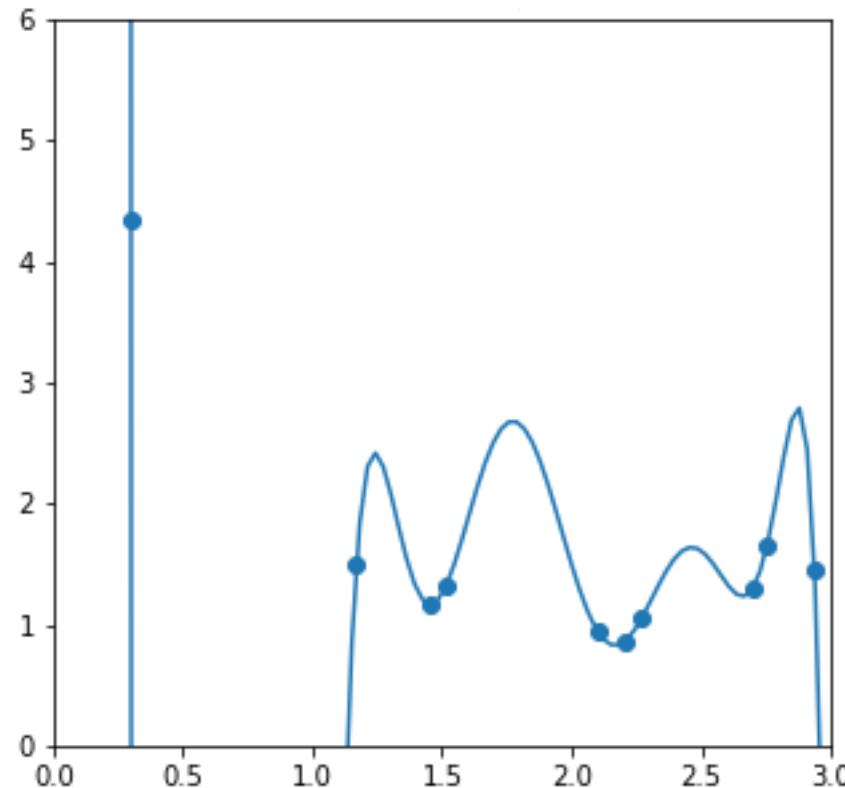
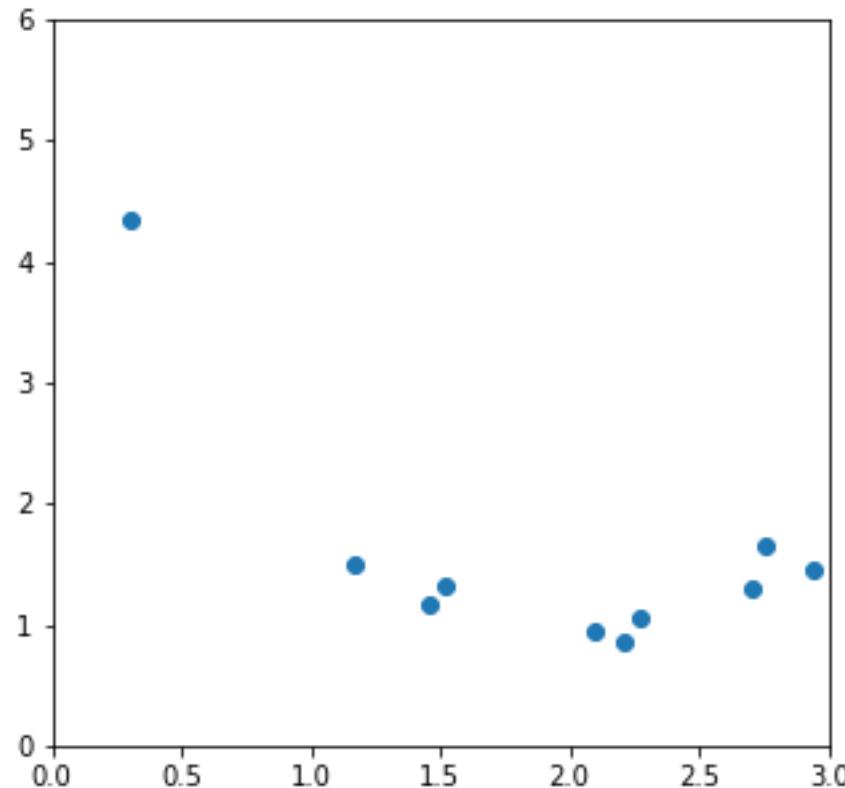
- Входные данные
- Признаки
- Модель
- Предсказание модели
- Метрики оценки

Практические асpekты

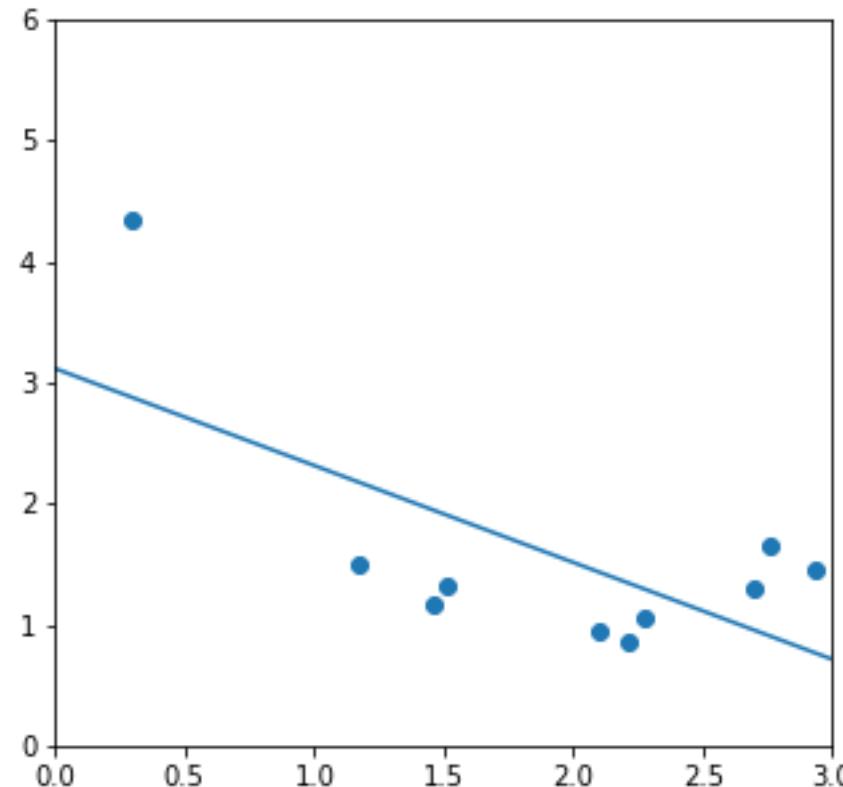
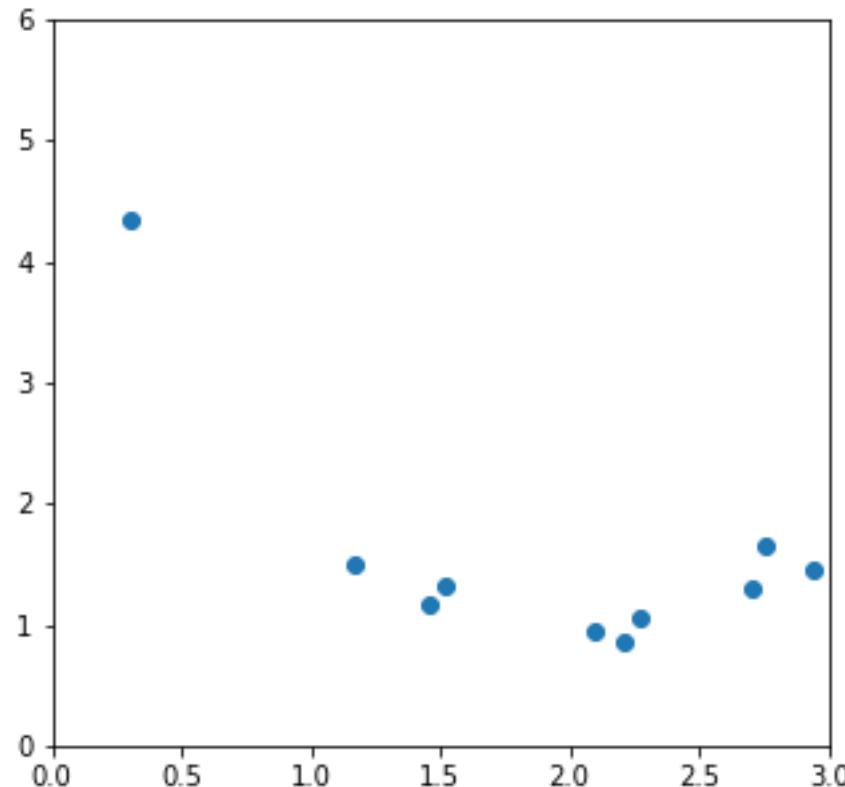
Недообучение и переобучение
Разделение на обучающую,
валидационную и тестовую выборки
Кросс-валидация
Метрики

10

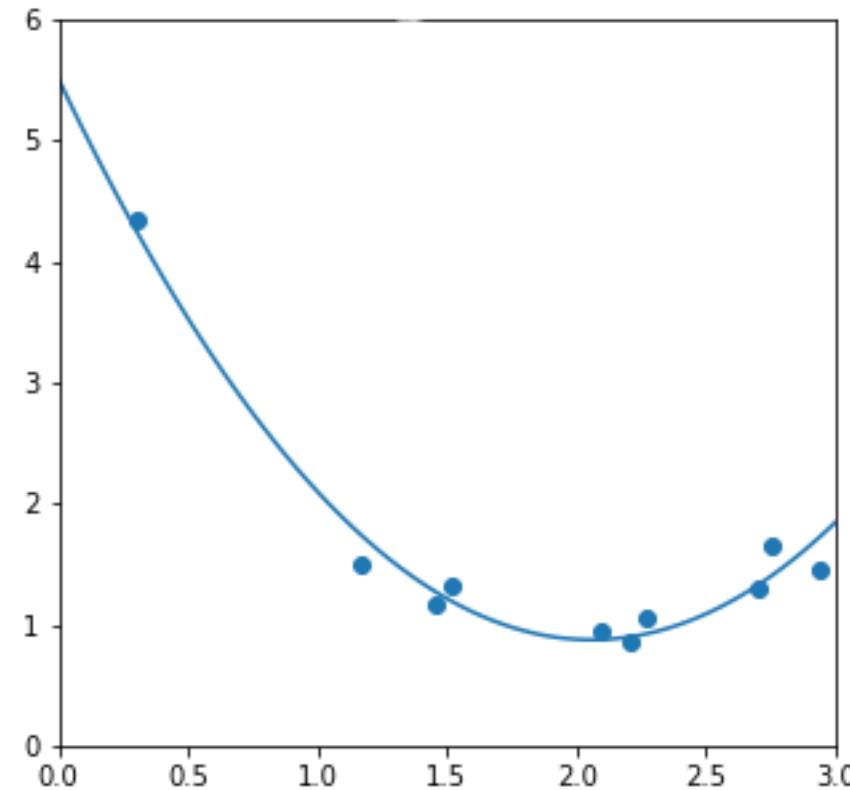
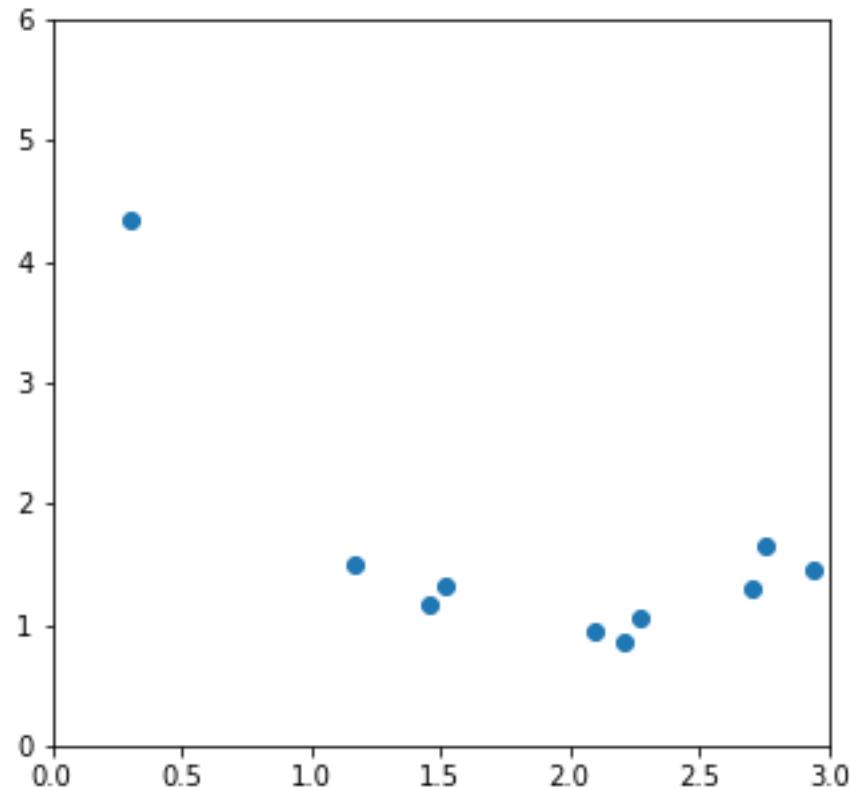
Выбираем класс функции



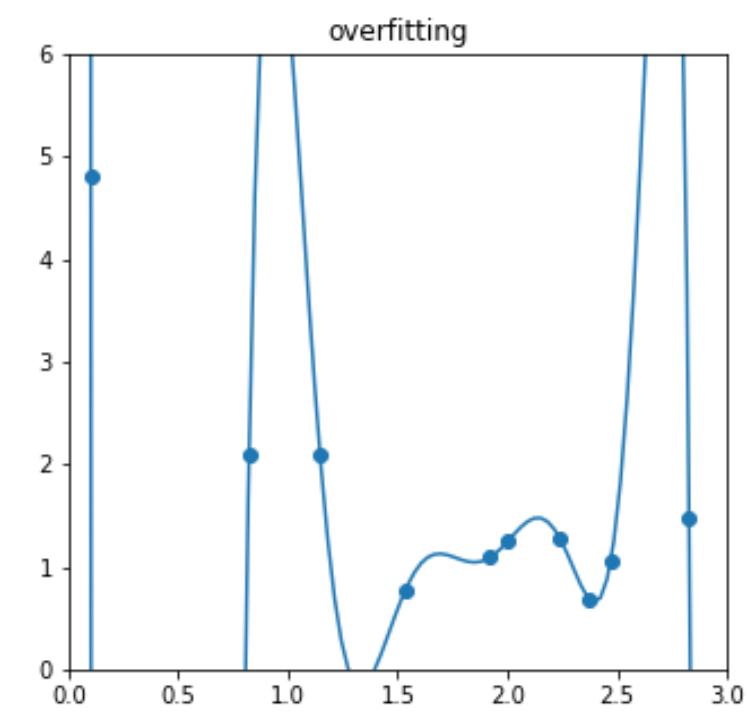
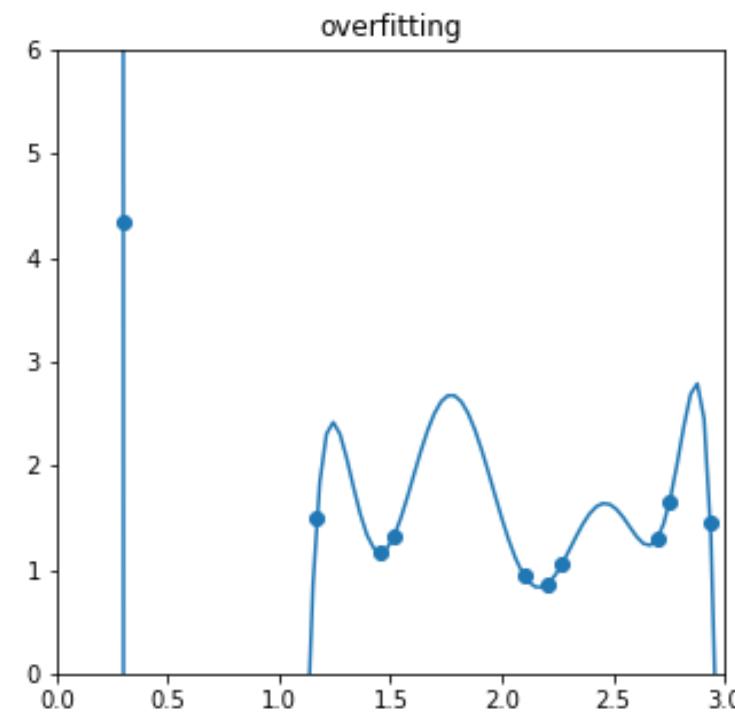
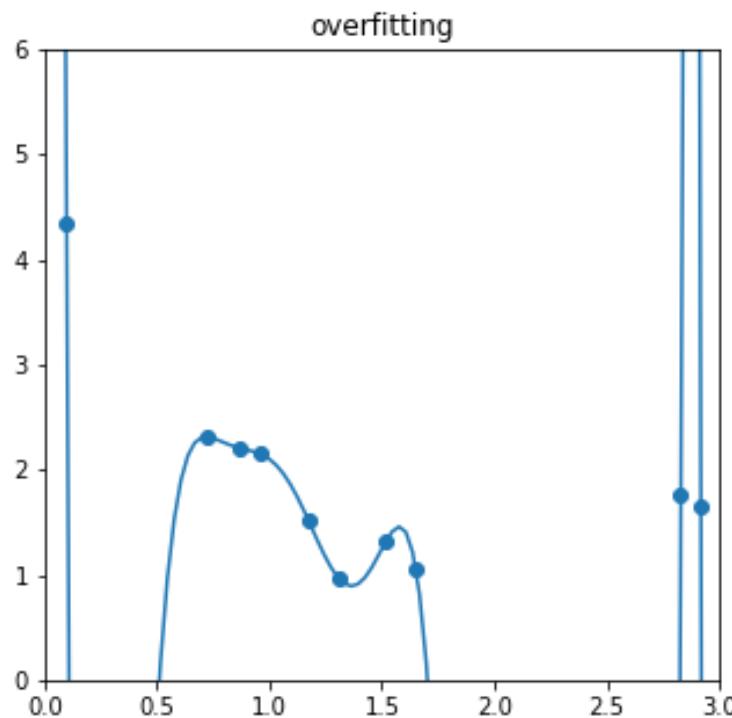
Выбираем класс функции



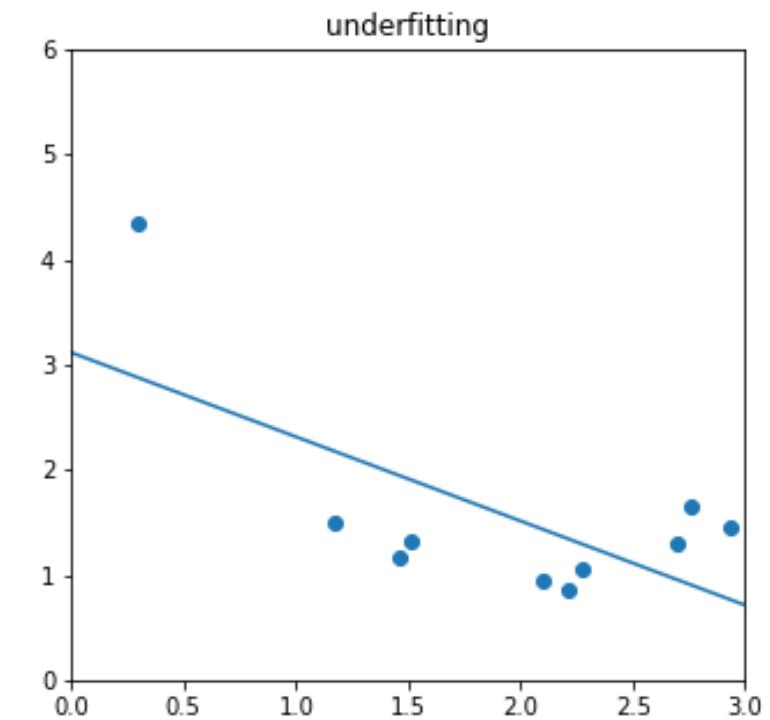
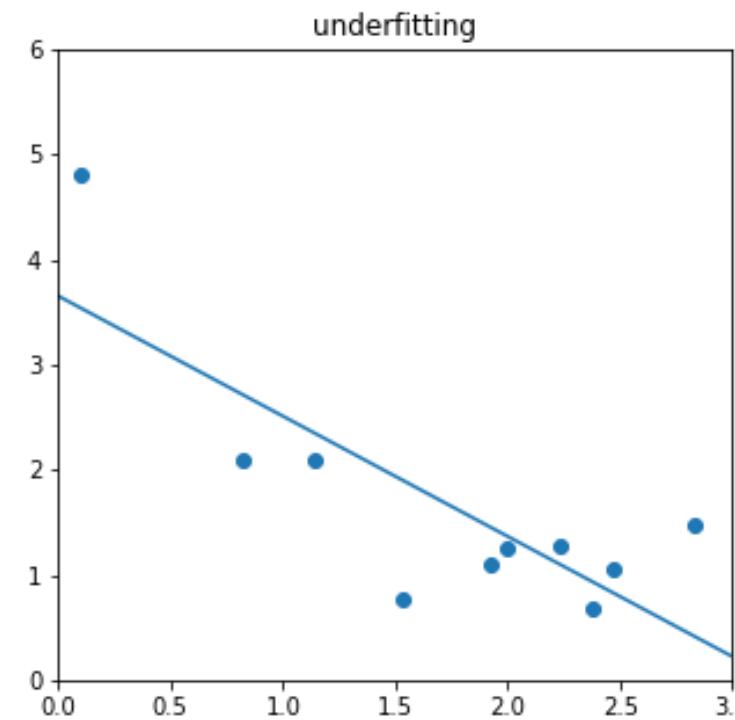
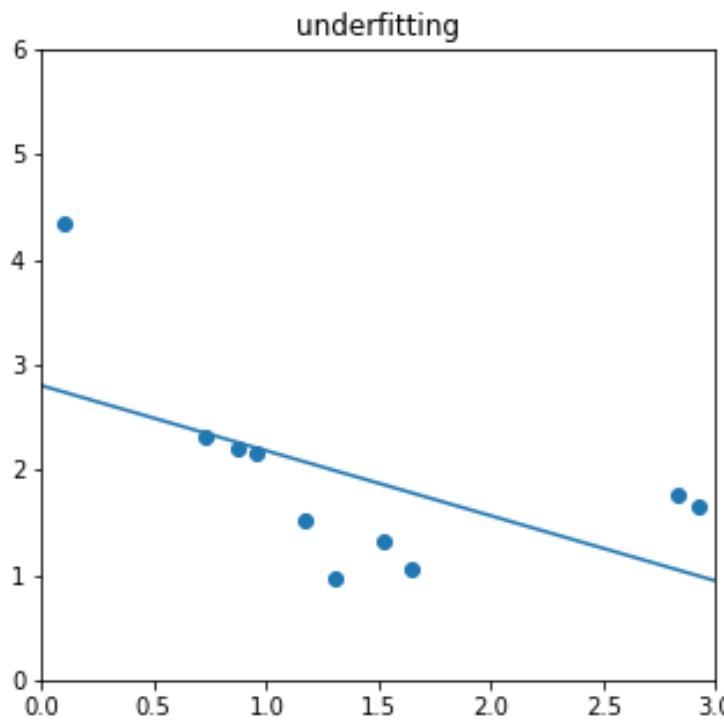
Выбираем класс функции



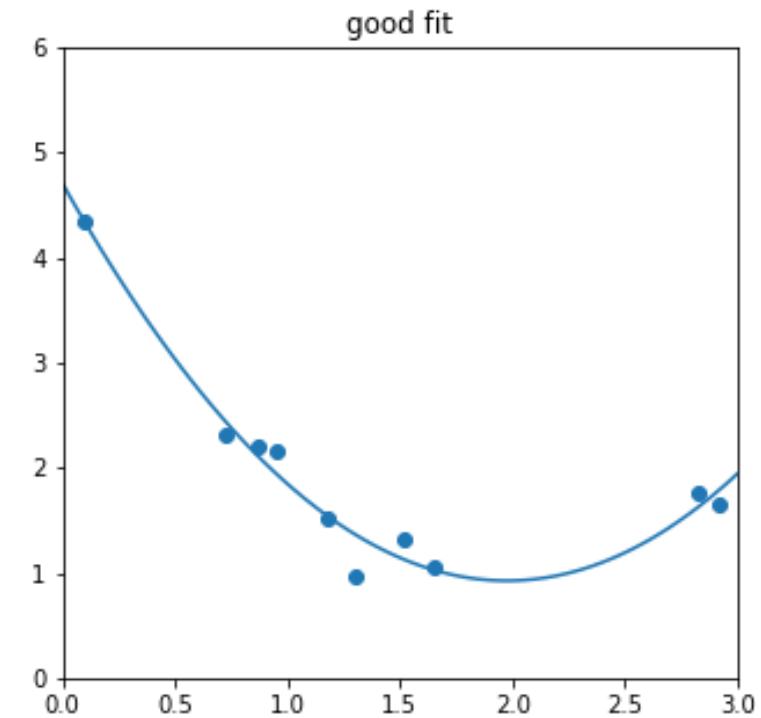
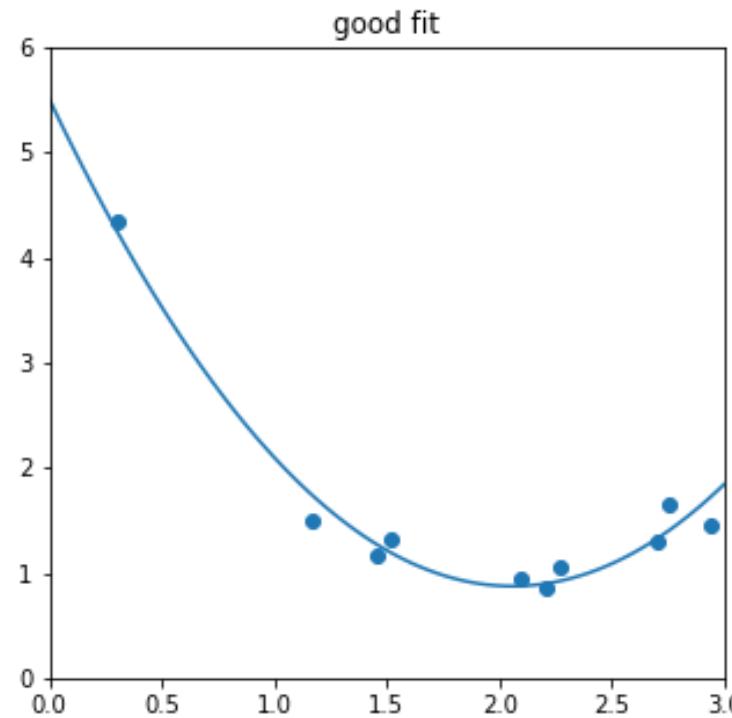
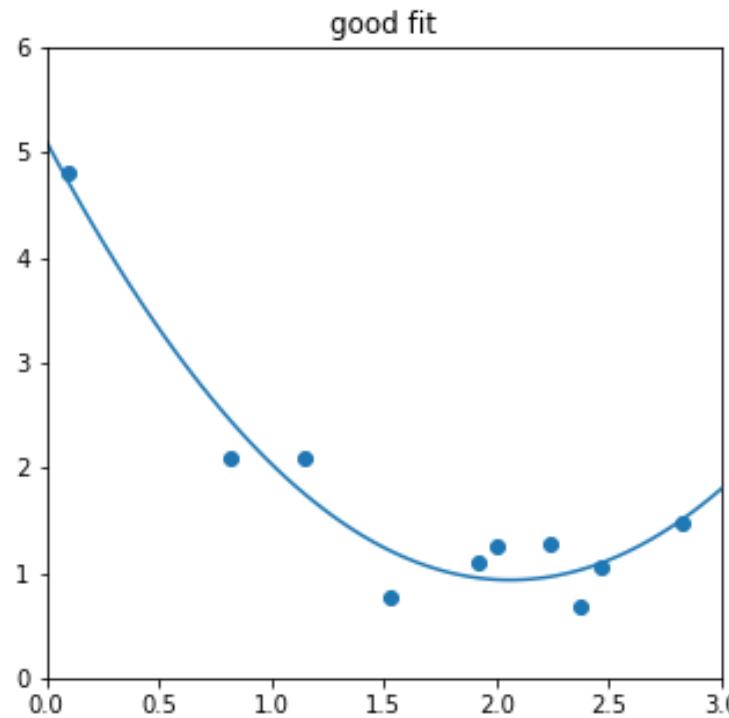
Разброс (Variance), переобучение



Смещение (Bias), недообучение



Оптимальные разброс и смещение



Переобучение (overfitting) и недообучение (underfitting)

- Модель с высоким смещением и низким разбросом (дисперсией) является недообученной моделью. Она недостаточно точно отражает статистические взаимосвязи в наших данных.
- Модель с высоким разбросом (дисперсией) и низким смещением является переобученной моделью, поскольку она улавливает взаимосвязи, слишком специфичные для конкретных данных, на которых мы ее обучаем. Эти взаимосвязи могут отсутствовать в общем распределении и, вероятно, являются ложными.

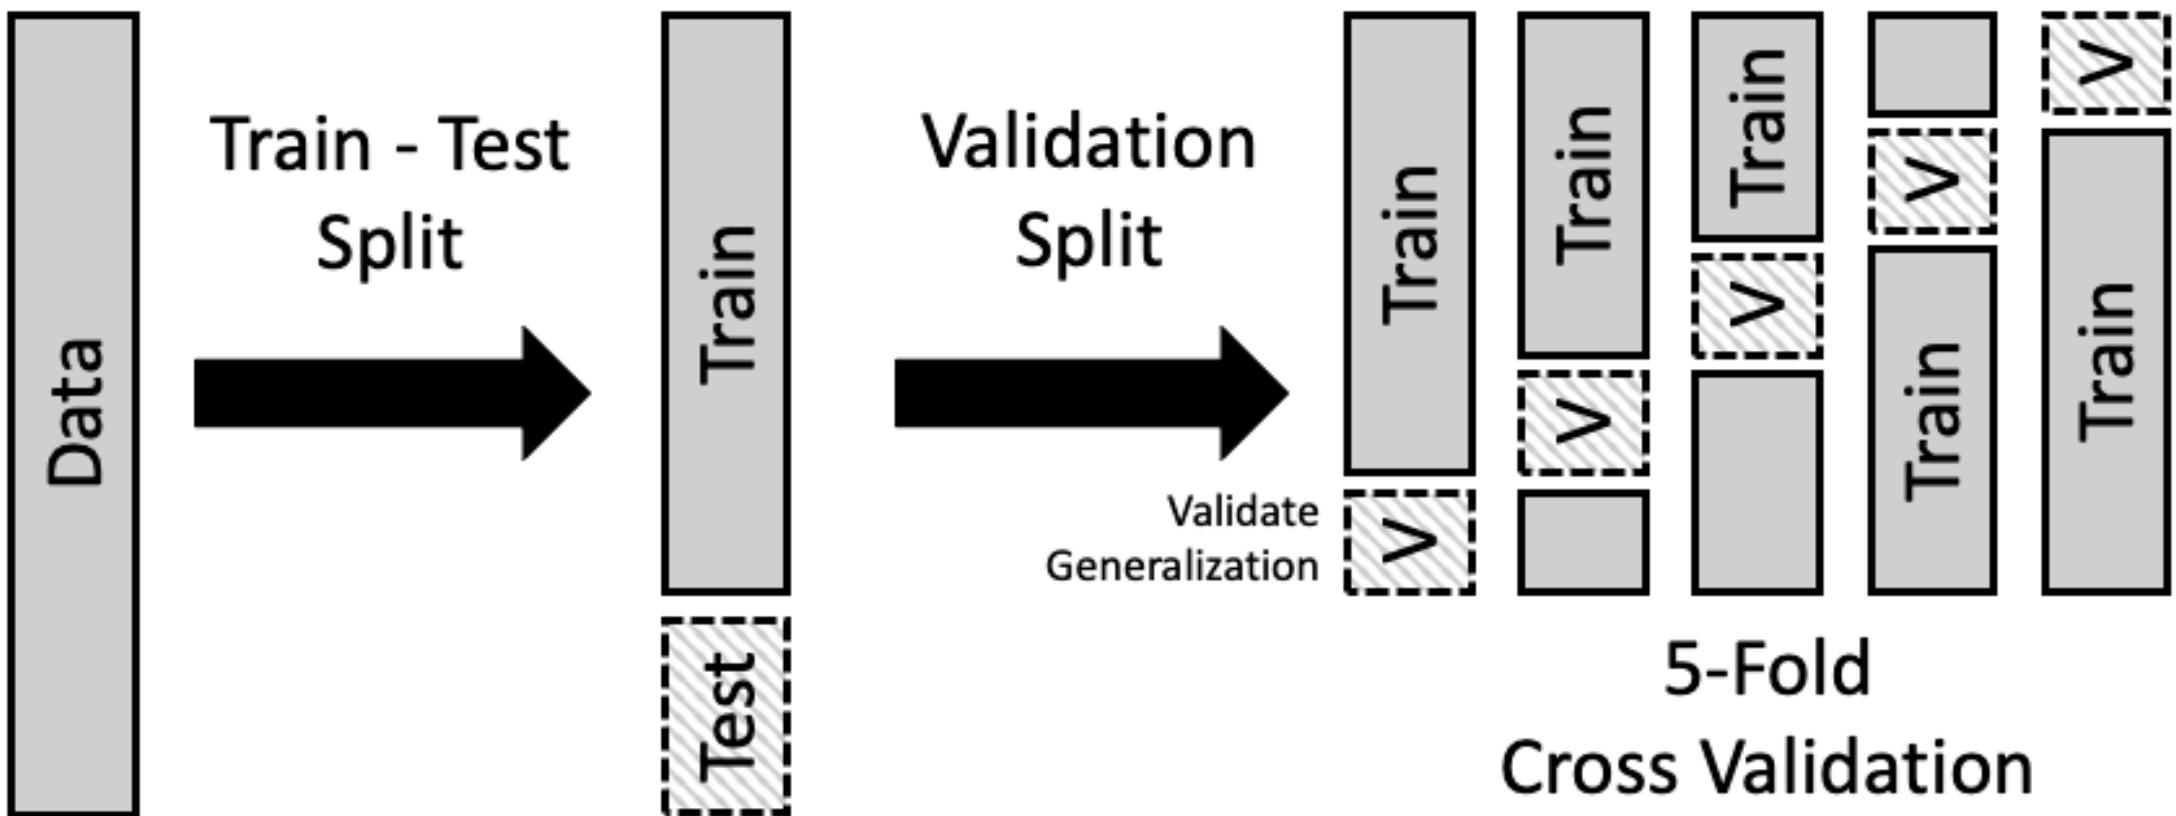
Разделение датасета (Dataset splitting)

- **Тренировочный набор данных**
 - Используется для обучения модели, позволяя ей изучать закономерности и взаимосвязи.
 - Как правило, составляет наибольшую часть данных (например, 60-70%).
- **Валидационный набор данных**
 - Используется для настройки параметров модели и предотвращения переобучения.
 - Помогает оценить производительность модели во время обучения, но не используется для непосредственного обучения модели.
- **Тестовый набор данных**
 - Полностью отдельный набор данных, используемый для окончательной оценки модели.
 - Обеспечивает объективную оценку производительности модели на новых данных.

Кросс валидация

- **Цель:** Подход, позволяющий максимально эффективно использовать данные для обучения и валидации.
- **Процесс:** Набор данных разбивается на k «складок». Каждая складка используется в качестве валидационного набора, а оставшиеся $k-1$ складки — для обучения.
- **Распространенный подход:** k -складочная перекрестная валидация (например, 5-складочная), где результаты усредняются по всем складкам.
- **Преимущество:** Обеспечивает более надежную оценку, снижая риск переобучения и недообучения.

Кросс-валидация



Данные в машинном обучении

- Данные — основа. Модели полагаются на данные для обучения и прогнозирования.
- Качество имеет значение. Высококачественные данные = точные модели; некачественные данные = неточные, предвзятые результаты.
- Более эффективные решения. Чистые данные приводят к полезным выводам, которые способствуют принятию более эффективных решений.
- Снижает предвзятость. Репрезентативные данные помогают обеспечить справедливые и этичные результаты работы ИИ.
- Вывод: «Хорошие данные = хорошие модели».

Вызовы при работе с данными

1. Проблемы качества и целостности

- **Отсутствующие данные:** Данные часто неполны из-за незарегистрированных значений или ошибок во время сбора.
- **Шумные данные:** Данные со случайными ошибками или шумом, часто требующие методов очистки или шумоподавления.
- **Выбросы:** Экстремальные значения, которые могут искажать модели, особенно в чувствительных алгоритмах.
- **Дублирующиеся данные:** Множественные записи для одной и той же сущности могут исказить модель, придавая чрезмерный вес определенной информации.
- **Неправильные метки:** Неправильная маркировка в тестовых наборах данных может сбить с толку модели и снизить точность.

2. Проблемы распределения данных

- **Несбалансированные данные:** Непропорциональное представление классов, что может смещать модели в сторону преобладающего класса.
- **Асимметричное распределение данных:** Сильно асимметричные признаки могут влиять на точность модели, особенно для алгоритмов, предполагающих нормальное распределение.
- **Перекрытие границ классов:** Плохо определенные границы между классами затрудняют классификацию.
- **Временной дрейф (дрейф концепций):** Статистические свойства данных меняются со временем, что приводит к устареванию моделей.

3. Проблемы с признаками данных

- **Нерелевантные признаки:** Неинформационные признаки добавляют шум в процесс обучения модели.
- **Высокая размерность (проклятие размерности):** Слишком много признаков увеличивает вычислительную сложность и риск переобучения.
- **Взаимодействие признаков:** Сложные взаимосвязи между признаками трудно выявить.
- **Перекрытие границ классов:** Перекрывающиеся признаки затрудняют различение классов моделями.

4. Проблемы форматов представления данных

- **Несогласованное форматирование:** Различия в форматах данных (например, дат или единиц измерения) приводят к ошибкам обработки.
- **Гетерогенные источники данных:** Данные из разных источников с различными форматами и структурами усложняют интеграцию.
- **Неструктурированные данные:** Текст, изображения или аудио требуют специальной обработки для машинного обучения.

5. Безопасность данных

- **Вопросы конфиденциальности:** Конфиденциальная информация должна быть анонимизирована или обрабатываться с осторожностью.
- **Законы о защите данных:** Необходимо соблюдение таких правил, как GDPR или HIPAA.
- **Проблемы безопасности:** Утечки или нарушения безопасности данных могут поставить под угрозу конфиденциальные наборы данных.

6. Вызовы при разметке данных

- **Недостаточная разметка:** Небольшие или неправильно размеченные наборы данных снижают качество модели.
- **Дорогие процессы разметки:** Разметка вручную, особенно в специализированных областях (например, в медицине), обходится дорого.
- **Неоднозначность классов:** Неоднозначные метки затрудняют точное обучение моделей.

Что такое предобработка данных?



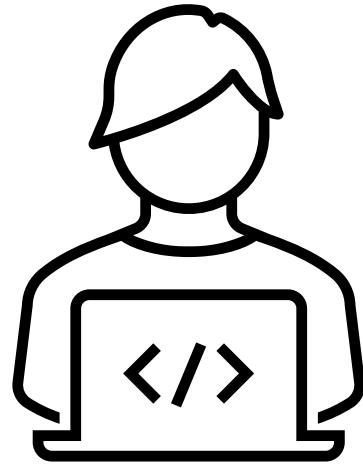
Ресурсы для изучения ML

- Scikit learn: <https://scikit-learn.org/stable/>
- Kaggle: <https://www.kaggle.com/>
- Machine Learning Mastery: <https://machinelearningmastery.com/>
- Books: <https://github.com/josephmisiti/awesome-machine-learning/blob/master/books.md>

Практика

Ресурсы для изучения ML

Лабораторные работы



32