

TECHNOLOGIES IN EDUCATION  
**UNIVERSITY** NSU

MICROELECTRONICS  
**INNOVATIONS**  
CATALYTIC  
MATERIALS  
**ASSEMBLY**  
**POINT** **DRUG**  
DESIGN

SCIENTIFIC  
LABORATORY  
**HYBRID**  
MATERIALS  
GEOPHYSICS  
**ENGINEERING**  
ENERGY CONSERVATION  
**BIOTECHNOLOGY**  
GEOCHEMISTRY  
NANOTECHNOLOGY

**HIGH**  
ENERGIES  
SEMIOTICS  
**SCIENCE**  
MATHEMATICAL MODELING

IT  
DEEP  
LEARNING  
BRAIN  
STUDY  
COGNITIVE

DEVELOPMENT  
**ELEMENTARY**  
**PARTICLES**  
THE ARCTIC REGIONS  
**DARK**  
MATTER

**QUANTUM**  
TECHNOLOGIES  
BIOMEDICINE  
**APPLIED**  
STUDIES  
PHOTONICS  
**ASTRONOMY**  
GLOBAL PRIORITY  
**ASTROPHYSICS**  
BIOINFORMATICS

**LASER**  
**PHYSICS**  
KNOWLEDGE  
ECONOMY  
**GEOLOGY**  
ARCHEOLOGY  
TECHNOLOGIES

**N\*** Novosibirsk  
State  
University  
**\*THE REAL SCIENCE**

# Базовые методы ИИ

## Семинар 4

Глушенко Андрей Валерьевич  
*ФФ НГУ*

# Практические аспекты

Оптимальное решение  
Градиентное решение ЛР  
Оптимизаторы градиентного спуска  
L1-, L2-регуляризация  
Теорема Гаусса-Маркова  
Анализ остатков

# Оптимальное решение

В контексте регрессионного анализа понятие **оптимального решения** — это поиск таких параметров модели, которые минимизируют «ошибку» между предсказаниями алгоритма и реальными данными.

# Оптимальное решение

Для поиска оптимального решения нам необходим математический критерий — функция потерь (**Loss Function**).

Она показывает, насколько сильно мы ошиблись.


Чаще всего в регрессии используется Метод наименьших квадратов (МНК). В этом случае оптимальным считается решение, при котором сумма квадратов отклонений минимальна:

$$RSS = \sum_{i=1}^n (y_i - \hat{y}_i)^2 \rightarrow \min$$

- $y_i$  — реальное значение.
- $\hat{y}_i$  — предсказанное значение.

# Понятие градиентного спуска

Градиентный спуск — это итерационный алгоритм оптимизации, который используется для поиска минимума функции.




# Аналитическое решение ЛР

Имеем решение  
нормального уравнения:

$$w = (X^T X)^{-1} X^T y$$

- нашли веса за 1 шаг



## Вызовы:

- Главная проблема аналитического решения — необходимость инвертирования (обращения) матрицы  $X^T X$ 
  1. Если у нас  $n$  признаков (фичей), то сложность обращения достигает  $O(n^3)$
  2. Матрица  $X^T X$  не всегда обратима. Если признаки сильно коррелируют между собой, аналитическое решение может стать неустойчивым.
- Если набор данных весит **100 ГБ**, а у нас **16 ГБ RAM**, аналитическое решение «вылетит» с ошибкой памяти.

Решение: Изучая градиентный спуск на линейной регрессии, мы осваиваем универсальный «движок», на котором работает почти весь современный Deep Learning.

# Градиентное решение ЛР

— это итеративный способ подбора весов модели, при котором параметры постепенно изменяются в сторону уменьшения функции ошибки.

- В отличие от точного аналитического решения, этот метод эффективен на огромных наборах данных



## Градиентное решение ЛР. Алгоритм:

1. Инициализация: Веса  $w$  и сдвиг  $b$  задаются случайными значениями или нулями.

2. Предсказание:  $\hat{y} = w \cdot x + b$

3. Расчёт ошибки:  $MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 = L$

4. Вычисление градиента:

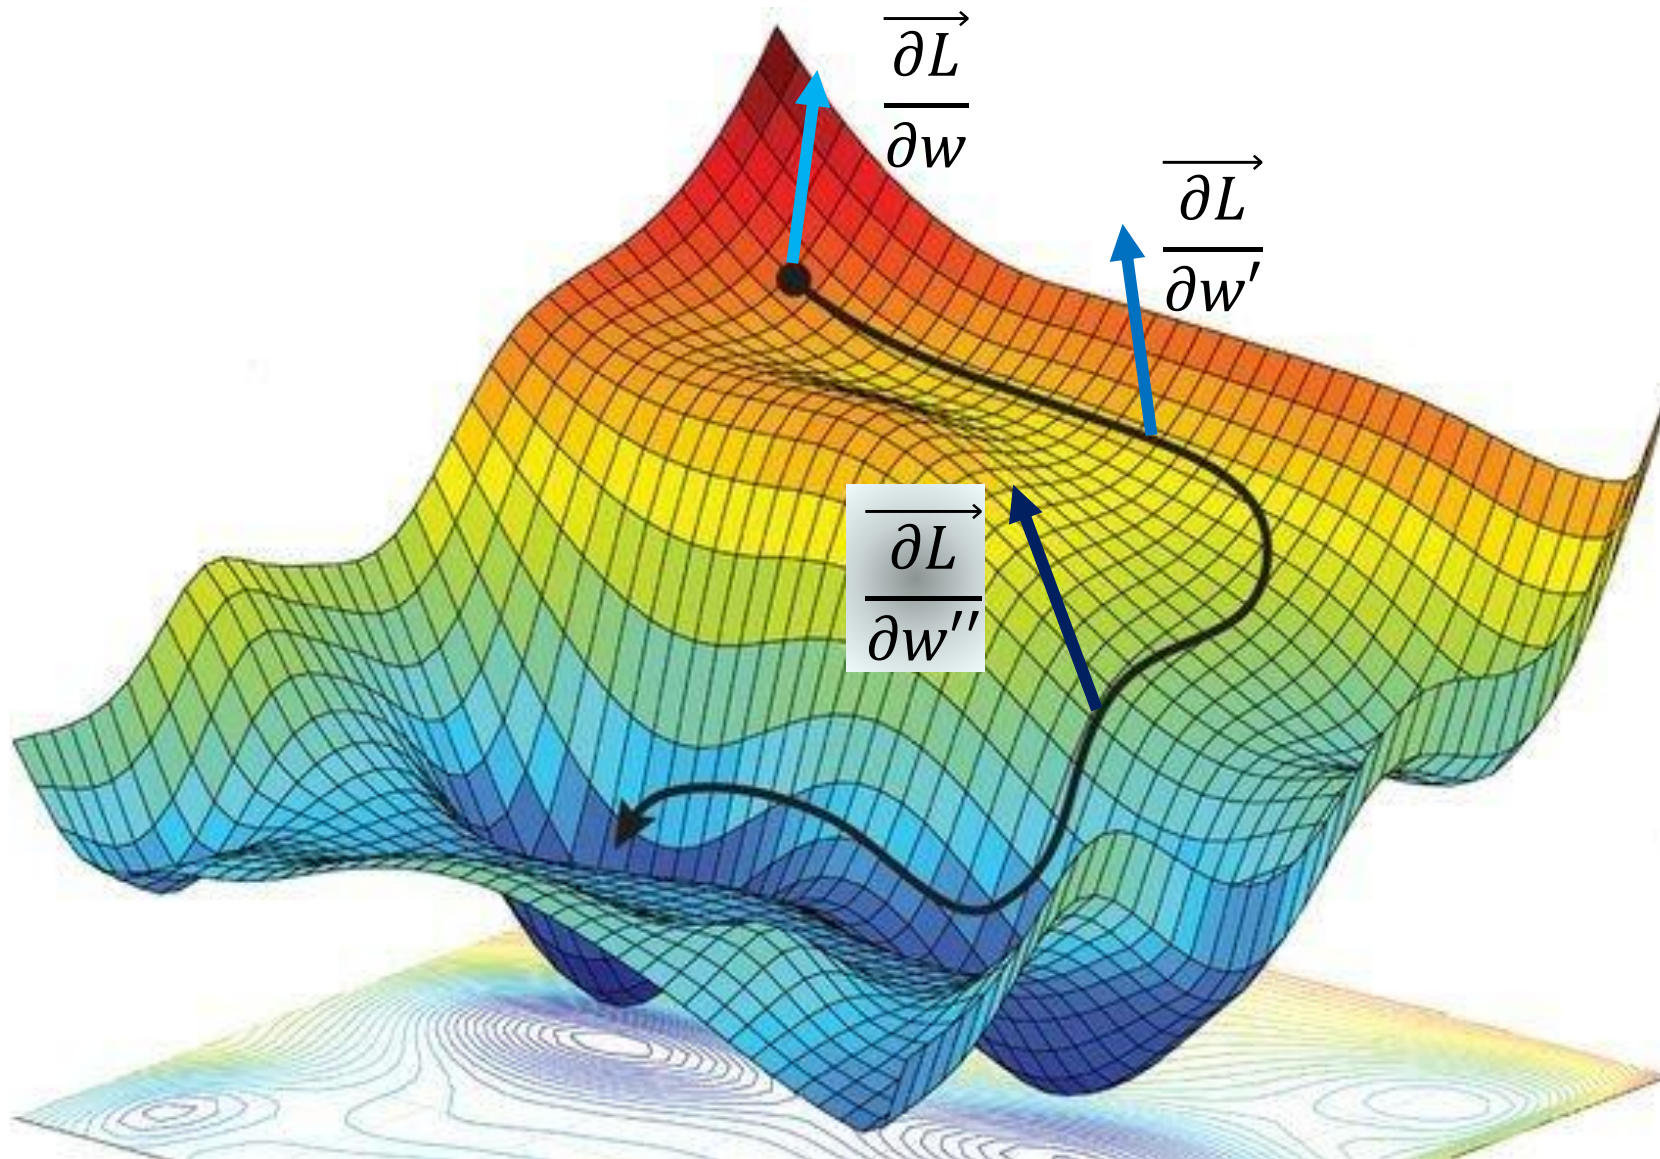
$$\frac{\partial L}{\partial w_j} = \frac{1}{m} \sum_{i=1}^m 2(\hat{y}_i - y_i) \frac{\partial (\hat{y}_i - y_i)}{\partial w_j} = \frac{2}{m} \sum_{i=1}^m (\hat{y}_i - y_i) x_{ij}, \quad \frac{\partial L}{\partial b} = \frac{2}{m} \sum_{i=1}^m (\hat{y}_i - y_i)$$

5. Обновление весов:

$$w_{new} = w_{old} - \alpha \frac{\partial L}{\partial w_{old}}, \quad b_{new} = b_{old} - \alpha \frac{\partial L}{\partial b_{old}}$$

$\alpha$  – скорость обучения (гиперпараметр), определяет размер шага

# Градиентное решение ЛР



# Vanilia SGD (Stochastic Gradient Descent)


В обычном градиентном спуске мы считаем ошибку по **всем** данным, прежде чем один раз обновить веса. Если данных миллион, это очень долго.

Vanilia SGD:

1. Выбирает **один случайный объект** из обучающей выборки
2. Считает градиент только для этого объекта
3. Мгновенно обновляет веса:  $w = w - \alpha \nabla L$
4. Повторяет это для следующего случайного объекта


# Vanilia SGD (Stochastic Gradient Descent)

- Рандомизация позволяет выйти из локального минимума



# Vanilia SGD (Stochastic Gradient Descent)

- Чувствителен к настройке гиперпараметра  $\alpha$
- График зависимости Loss с ростом числа итераций:





# Оптимизаторы градиентного спуска

Когда мы переходим от простого градиентного спуска (Vanilla SGD) к реальным задачам, мы сталкиваемся с проблемами:

- алгоритм может застревать в локальных минимумах
- алгоритм может «осциллировать» (сильно прыгать из стороны в сторону)
- алгоритм может обучаться слишком медленно.

Для решения этой проблемы существуют оптимизаторы — надстройки над градиентным спуском, которые адаптивно меняют скорость обучения (*learning rate*)  $\alpha$ .

# Адаптивные оптимизаторы

## RMSProp (Root Mean Square Propagation):

- Идея: Алгоритм хранит «бегущее среднее» от квадратов градиентов. Иными словами, благодаря ограничению колебаний не допускается бесконечный рост весов
- $s_t = \beta \cdot s_{t-1} + (1 - \beta)g_t^2$  — обновление среднего квадрата градиента,
- $\beta$  — гиперпараметр сглаживания (обычно = 0,9)
- $w_{t+1} = w_t - \frac{\alpha}{\sqrt{s_t + \epsilon}} g_t$
- $\alpha$  — скорость обучения (learning rate)
- $\epsilon$  — малое число ( $10^{-8}$ ) для предотвращения деления на 0

# Адаптивные оптимизаторы

**AdaDelta** (решает проблему AdaGrad, где знаменатель рос бесконечно)

- Проблема: В предшественнике (AdaGrad) скорость обучения со временем падала до нуля, и обучение просто останавливалось.
- Решение: AdaDelta ограничивает окно накопленных градиентов фиксированным размером
- Особенность: В базовой версии AdaDelta даже не нужен начальный learning rate — оптимизатор вычисляет его сам.



# Адаптивные оптимизаторы

## **Adam (Adaptive Moment Estimation)**

Король современных оптимизаторов. Он объединяет в себе две идеи:

- Momentum (Инерция): Накапливает «скорость» градиента, чтобы пролетать плоские участки и мелкие ямки.
- RMSProp: Адаптирует шаг для каждого веса отдельно.

# Теорема Гаусса-Маркова

— это фундаментальный принцип в статистике, который дает теоретическое обоснование того, почему мы вообще используем метод наименьших квадратов (МНК/OLS) для линейной регрессии.

# Теорема Гаусса-Маркова

Условия классической линейной регрессии:

- Линейность параметров:  $\hat{y} = w_1x_1 + w_2x_2 + w_3x_3^2$   ~~$(+ e^{w_3}x_3)$~~
- Полный ранг матрицы признаков (Отсутствие мультиколлинеарности, матрица  $X^T X$  обратима)
- Экзогенность (Нулевое матожидание ошибки): ошибки должны быть случайными и не зависеть от того, какие значения принимают  $x_i$
- Гомоскедастичность (Постоянная дисперсия): Если при малых значениях  $x_i$  модель ошибается чуть-чуть, а при больших модель имеет огромный разброс, это называется гетероскедастичностью
- Отсутствие автокорреляции: ошибки разных наблюдений не должны зависеть друг от друга

# Теорема Гаусса-Маркова

Теорема утверждает, что при соблюдении условий классической линейной регрессии, оценка МНК является **BLUE** (Best Linear Unbiased Estimator).

- Best (Лучшая): Она обладает минимальной дисперсией. Это значит, что оценки весов будут максимально стабильными от выборки к выборке
- Linear (Линейная): Оценка весов представляет собой линейную комбинацию наблюдаемых значений зависимой переменной
- Unbiased (Несмещенная): В среднем оценка весов будет равна их истинному значению (она не систематически «промахивается» мимо истины)
- Estimator (Оценка): Алгоритм вычисления параметров

# Теорема Гаусса-Маркова


- Теорема не требует, чтобы ошибки были распределены нормально. Она говорит лишь о том, что даже без нормальности МНК — самый эффективный способ поиска весов среди всех линейных методов.
- Градиентный спуск в линейной регрессии сходится к тому же решению, что и аналитический МНК, теорема Гаусса-Маркова гарантирует, что результат будет обладать теми же свойствами BLUE (при соблюдении условий).

# Анализ остатков


— это «диагностика» обученной модели. Это процесс проверки того, насколько хорошо модель объяснила данные и не остались ли в ошибках какие-то скрытые закономерности

Остатки (residuals):  $e_i = y_i - \hat{y}_i$

Case 1: Assumptions are met



Case 2: Assumptions are not met




Case 3: Assumptions are not met



# Анализ остатков

- Остатки хаотично разбросаны вокруг нулевой линии.
- Плохо: Остатки образуют дугу, волну или кривую.
- Вывод: Взаимосвязь между  $x$  и  $y$  на самом деле не линейная (например, квадратичная), нужно добавить полиномиальные признаки  $x^k$


Case 1: Assumptions are met



# Анализ остатков. Проверка гомоскедастичности (из теоремы Г-М)

- Хорошо: Облако точек имеет примерно одинаковую ширину (высоту) на всем протяжении.
- Плохо: График напоминает «рупор» (сначала узко, потом широко).
- Вывод: Дисперсия ошибки непостоянна. Это нарушает условия BLUE, и доверие к коэффициентам модели падает.

Case 2: Assumptions are not met Case 3: Assumptions are not met






# Анализ остатков. Проверка нормальности распределения


Строим гистограмму остатков или график Q-Q plot.

- Хорошо: Гистограмма напоминает «колокол» (нормальное распределение).
- Вывод: Если остатки распределены нормально, мы можем строить надежные доверительные интервалы и проверять статистическую значимость весов (p-values).

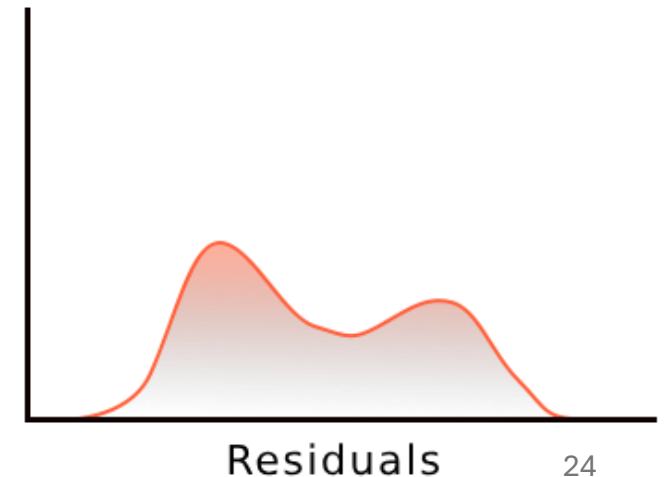
Case 1: Assumptions are met



Case 2: Assumptions are not met



Case 3: Assumptions are not met



# Лабораторная работа

Градиентное решение ЛР

Оптимизаторы градиентного спуска

Теорема Гаусса-Маркова

Анализ остатков

25