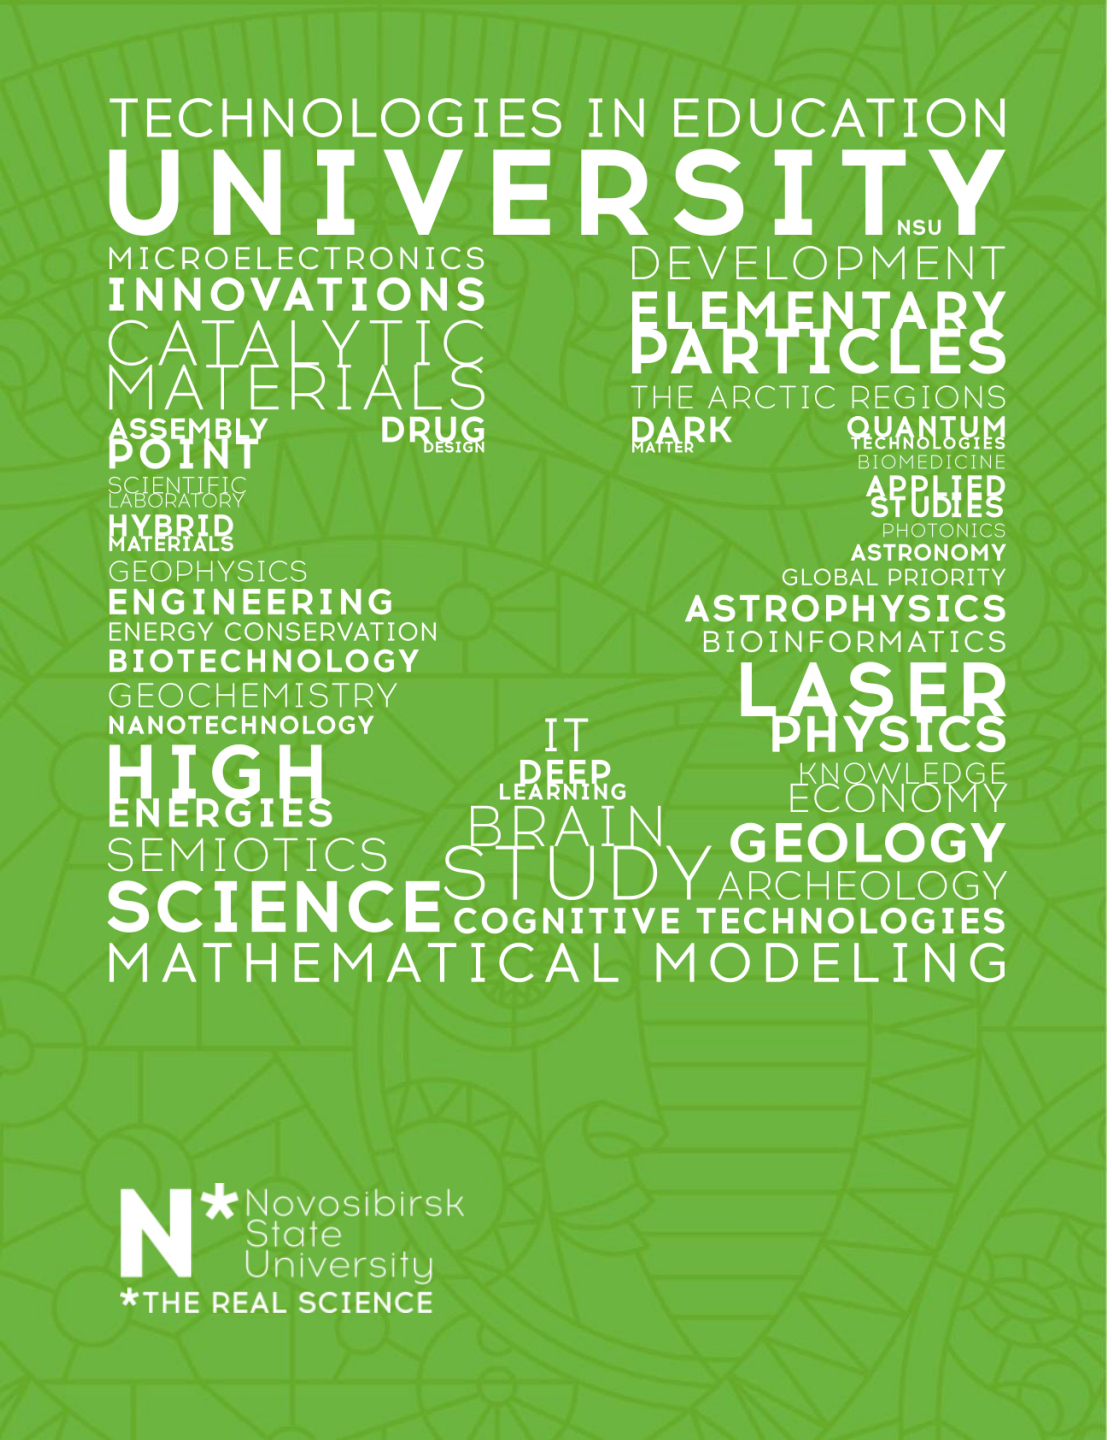

Базовые методы ИИ
Семинар 6

Глушенко Андрей Валерьевич
ФФ НГУ

Метрические методы классификации

Метрические методы классификации строятся на простом принципе: «похожие объекты лежат рядом».

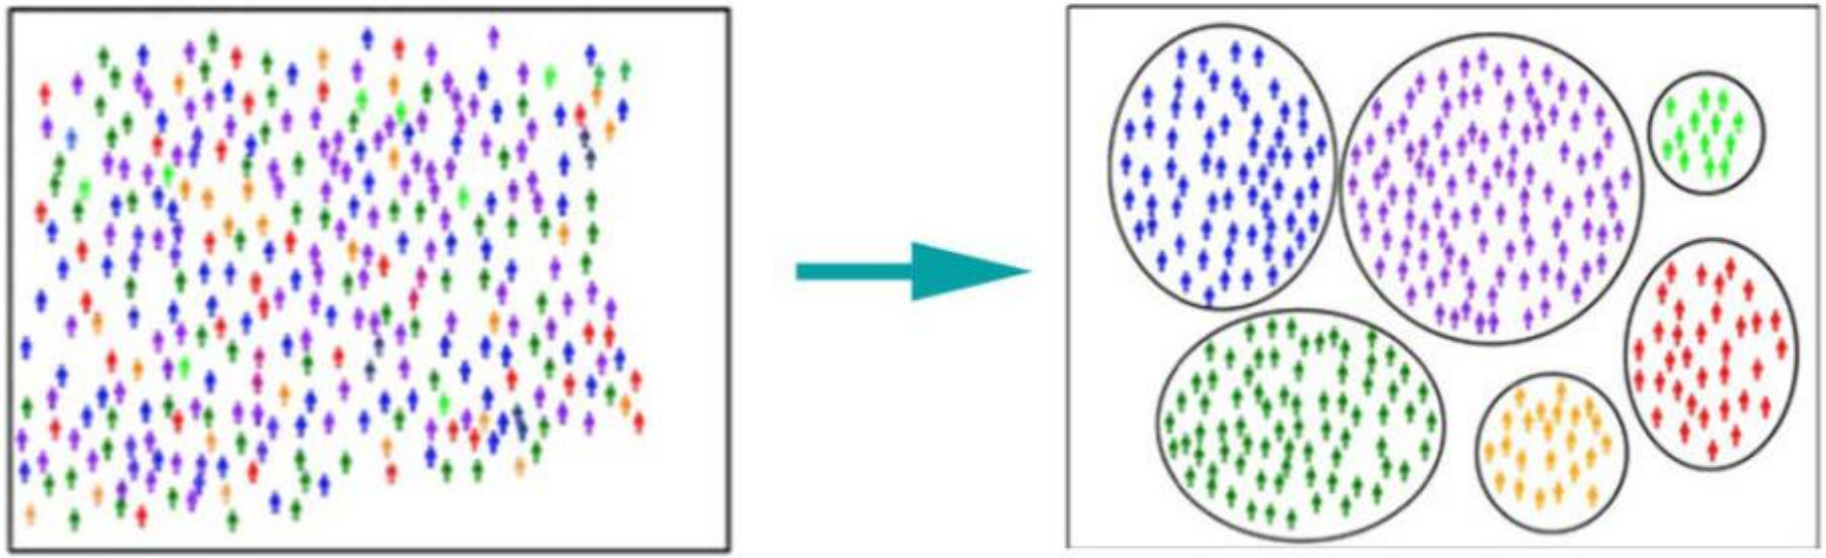

Плюсы и минусы метрических методов

- **Плюсы:**
  - Интуитивно понятны
  - Не требуют сложного «обучения» (модель — это просто сохраненные данные)
  - Легко добавлять новые классы
- **Минусы:**
  - Работают медленно на огромных данных (нужно считать расстояния до всех точек)
  - Чувствительны к выбросам и требуют обязательного масштабирования признаков (чтобы рост в сантиметрах не перевесил вес в граммах)

Как измеряется «близость» объекта?

- **Евклидово расстояние:** прямая линия между точками (самый частый вариант).
- **Манхэттенское расстояние:** сумма модулей разностей координат (как движение по кварталам города).
- **Расстояние Косинуса:** оценивает не длину, а угол между векторами (полезно в текстах)

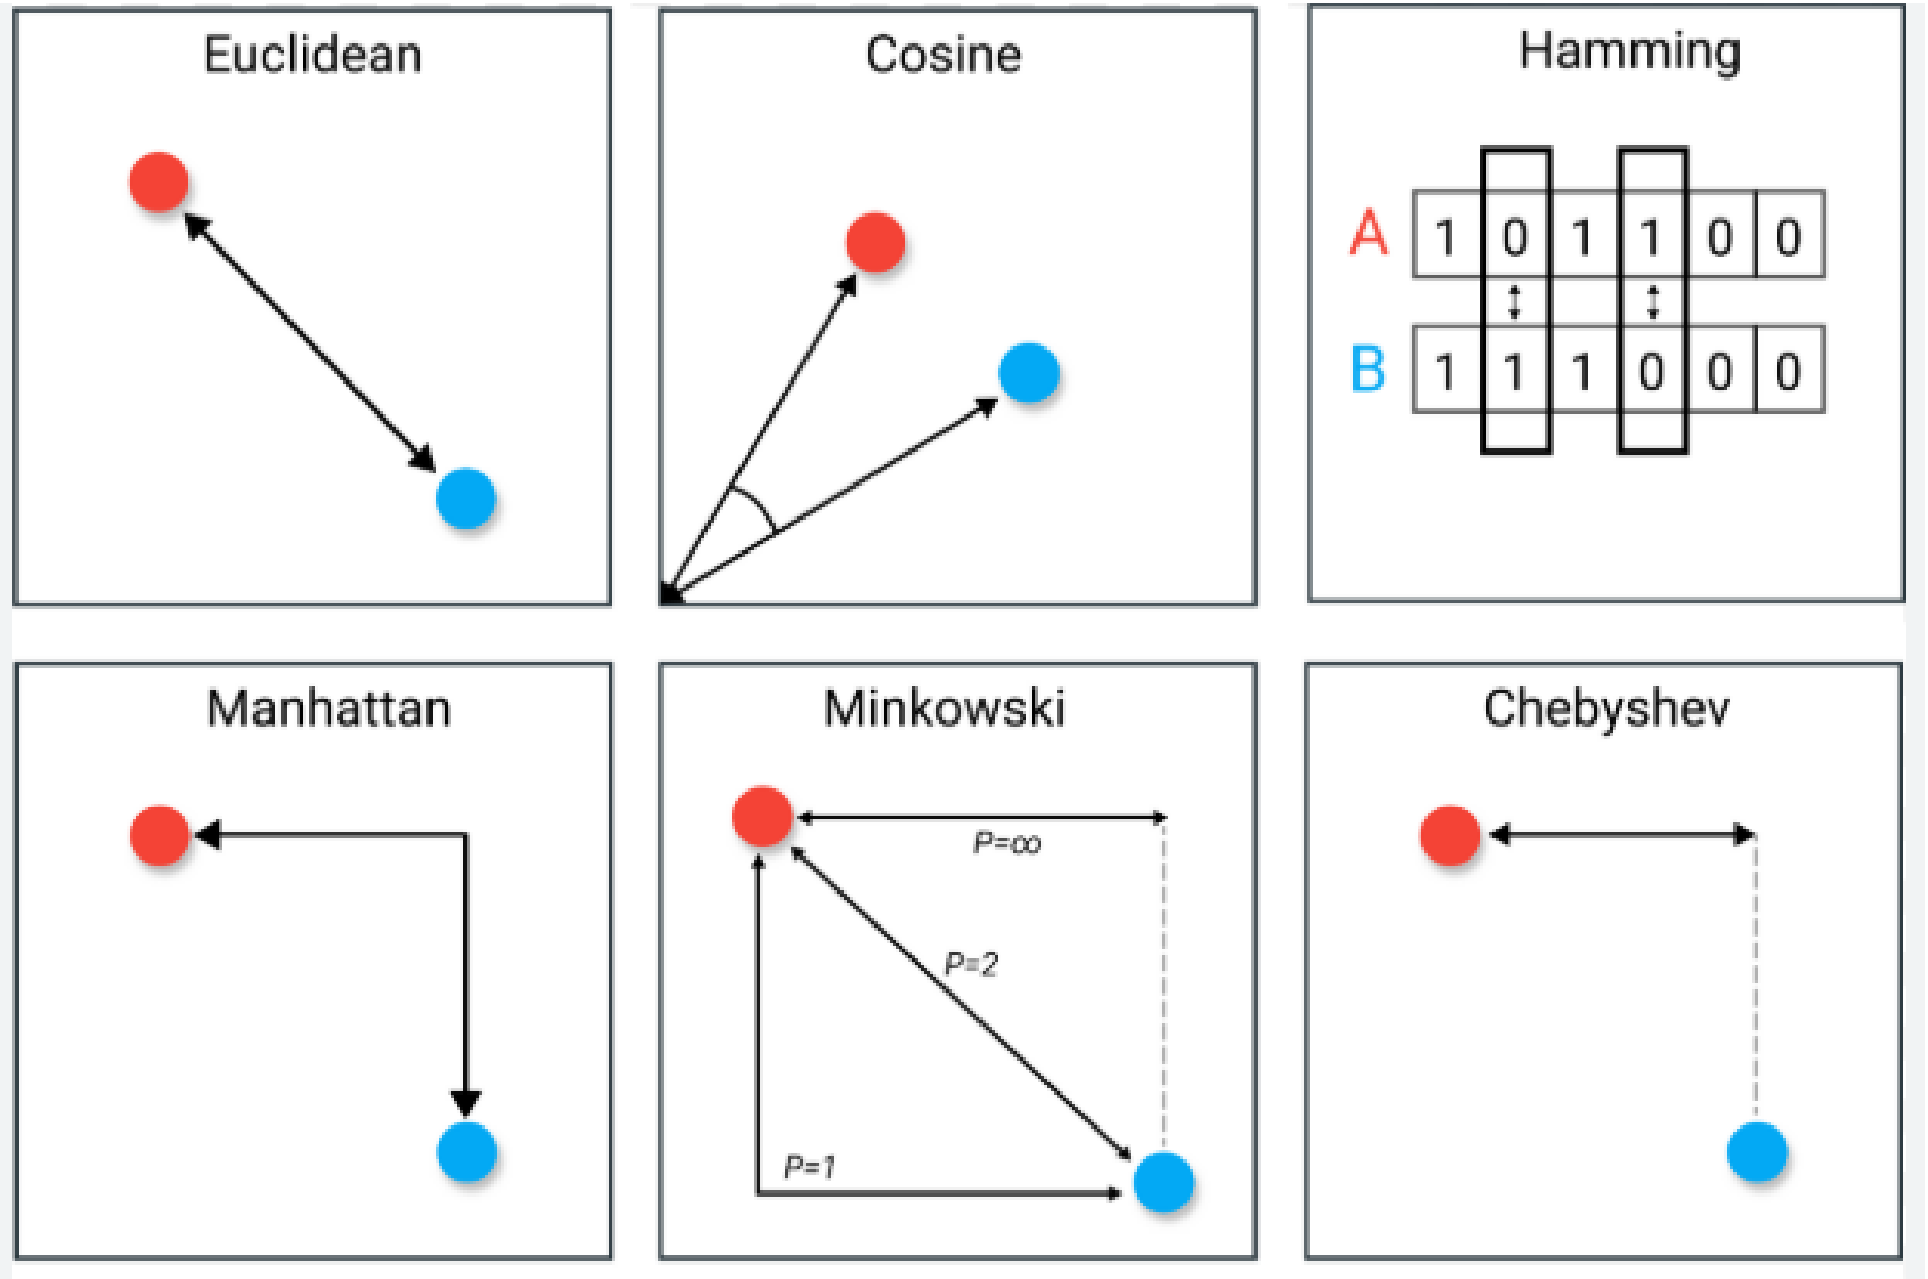
Euclidean
Cosine
Hamming
A
1 0 1 1 0 0
B
1 1 1 0 0 0
Manhattan
Minkowski
P=∞
P=2
P=1
Chebyshev

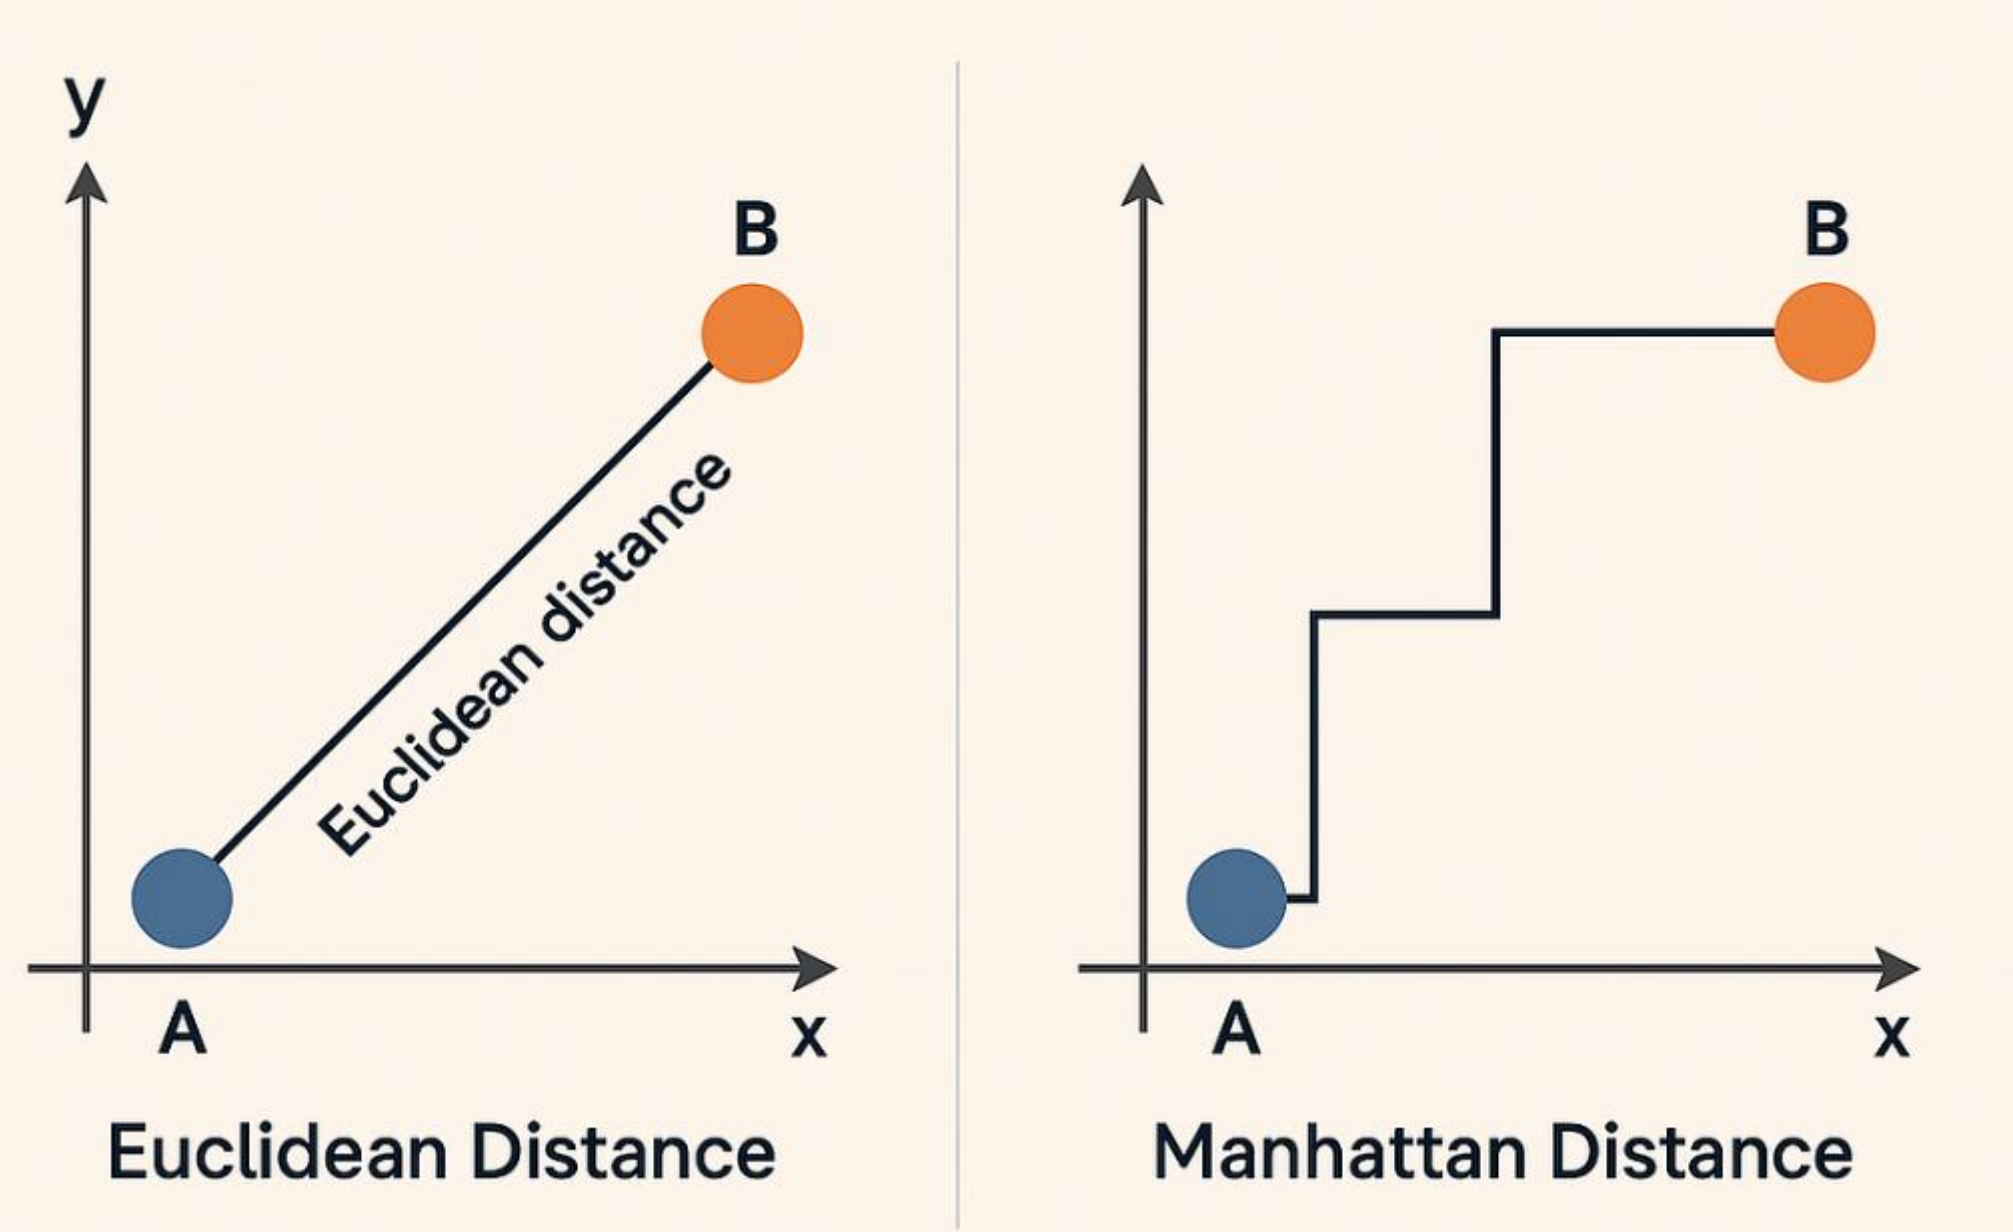
y
B
Euclidean distance
A
x
Euclidean Distance
B
A
x
Manhattan Distance

Метод k-ближайших соседей (k-NN)

- **Метод k-ближайших соседей —** это один из самых простых и эффективных алгоритмов машинного обучения. Его часто называют «ленивым», потому что он не строит математическую модель заранее, а просто запоминает все данные и начинает «думать» только в момент классификации.

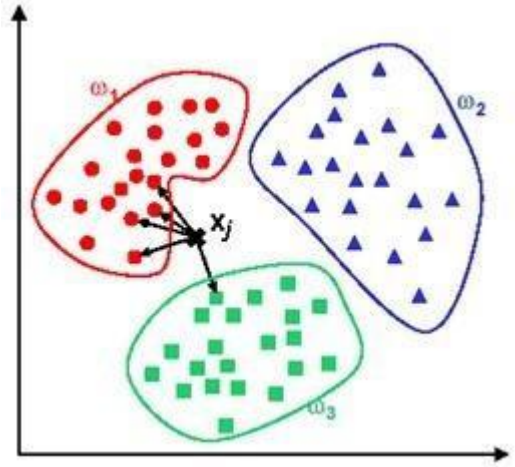

Метод k-ближайших соседей (k-NN). Алгоритм

1. Считаем расстояние от этого объекта до всех остальных точек в обучающей выборке.
2. Отбираем k объектов, у которых это расстояние минимально (это и есть наши «ближайшие соседи»).
3. Голосуем: смотрим, к каким классам относятся эти соседи. Тот класс, который встречается чаще всего, присваивается новому объекту.

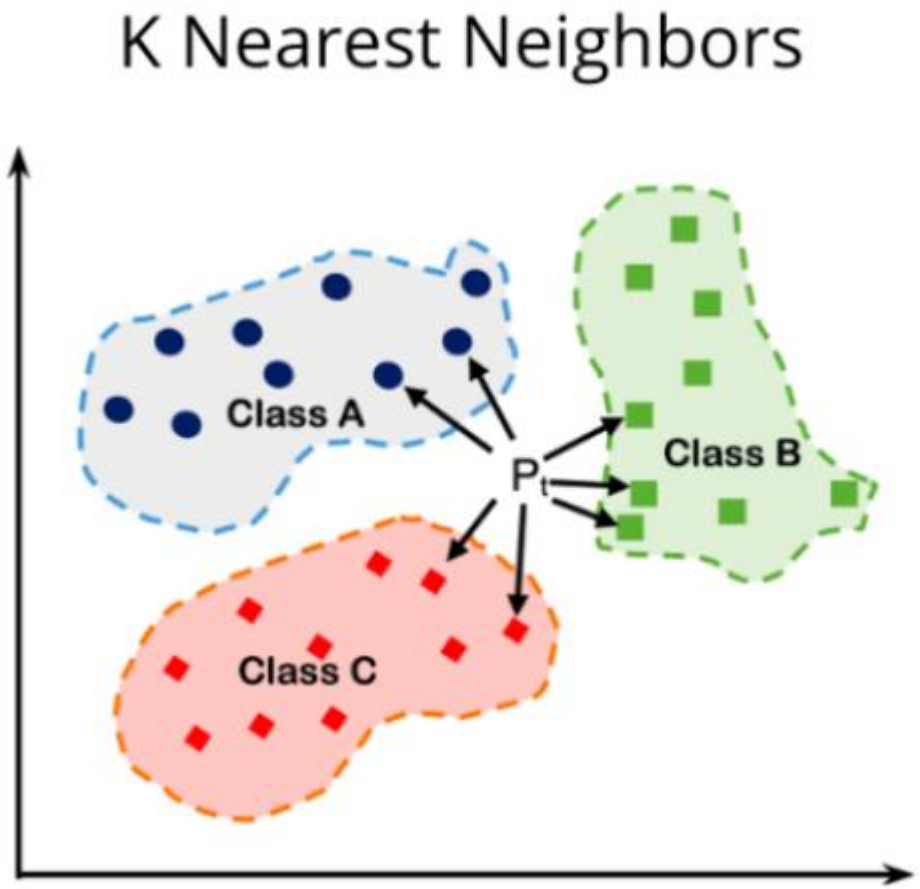

Метод k-ближайших соседей (k-NN). Алгоритм

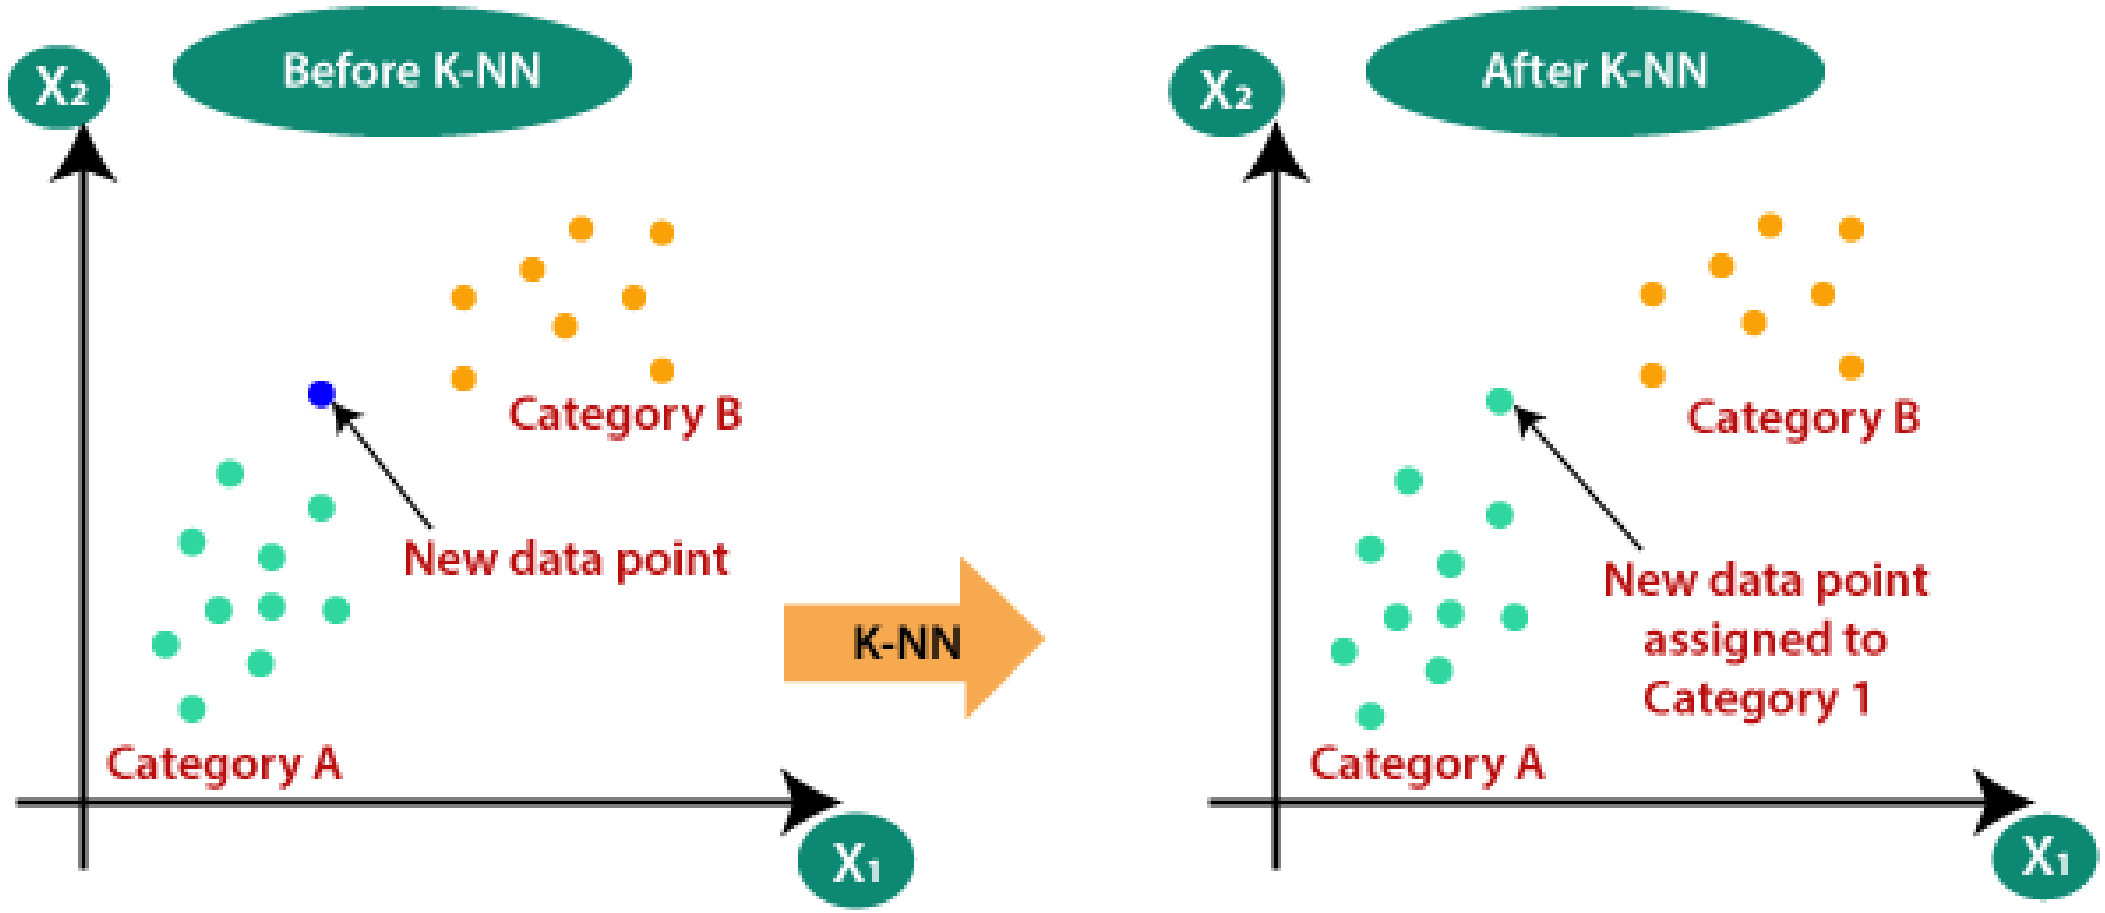

Выбор параметра k

Выбор количества соседей критически влияет на результат:

- **Малое k (например, 1):** Модель очень чувствительна к шуму. Одна аномальная точка в данных может «перетянуть» решение на себя. Это ведет к переобучению.
- **Большое k:** Границы между классами размываются. Модель становится слишком «усредненной», что ведет к недообучению.
- **Лайфхак:** Обычно выбирают нечетное число (3, 5, 7...), чтобы при голосовании двух классов не возникло ничьей.

Взвешенный k-NN (Weighted k-NN)

В базовой версии голос каждого соседа равен 1. Но логичнее предположить, что тот, кто стоит совсем рядом, «знает» правильный ответ лучше того, кто находится чуть дальше.

В этом случае голоса взвешиваются: чем меньше расстояние, тем больше вес голоса.

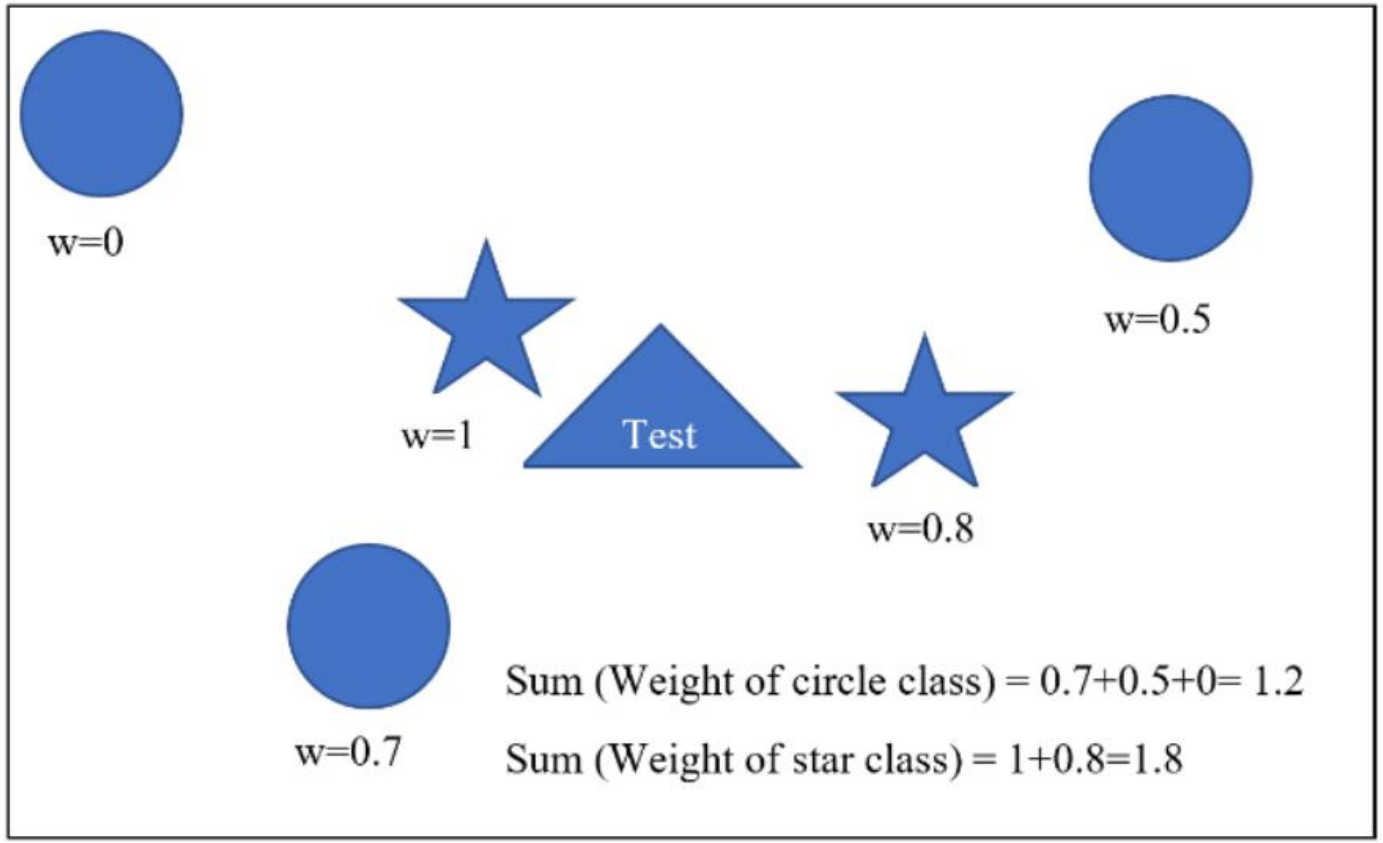

Важный нюанс: нормирование

Предположим, что у нас два признака: «количество детей» (от 0 до 5) и «годовой доход» (в миллионах). Расстояние по доходу будет всегда огромным и полностью подавит признак с детьми.

Без масштабирования (StandardScaler или MinMaxScaler) k-NN не работает адекватно.

Проблема размерности («Проклятие размерности»)

Чем больше признаков у объекта (столбцов в таблице), тем хуже работает метод. В многомерном пространстве все точки становятся одинаково далекими друг от друга, и понятие «близости» теряет смысл.

- Плюсы:
  - Просто понять и объяснить.
  - Нет этапа долгого обучения.
  - Легко адаптируется под многоклассовую классификацию.
- Минусы:
  - Память: Нужно хранить все данные в оперативной памяти.
  - Скорость: Если данных миллионы, расчет расстояний для каждой новой точки займет вечность.