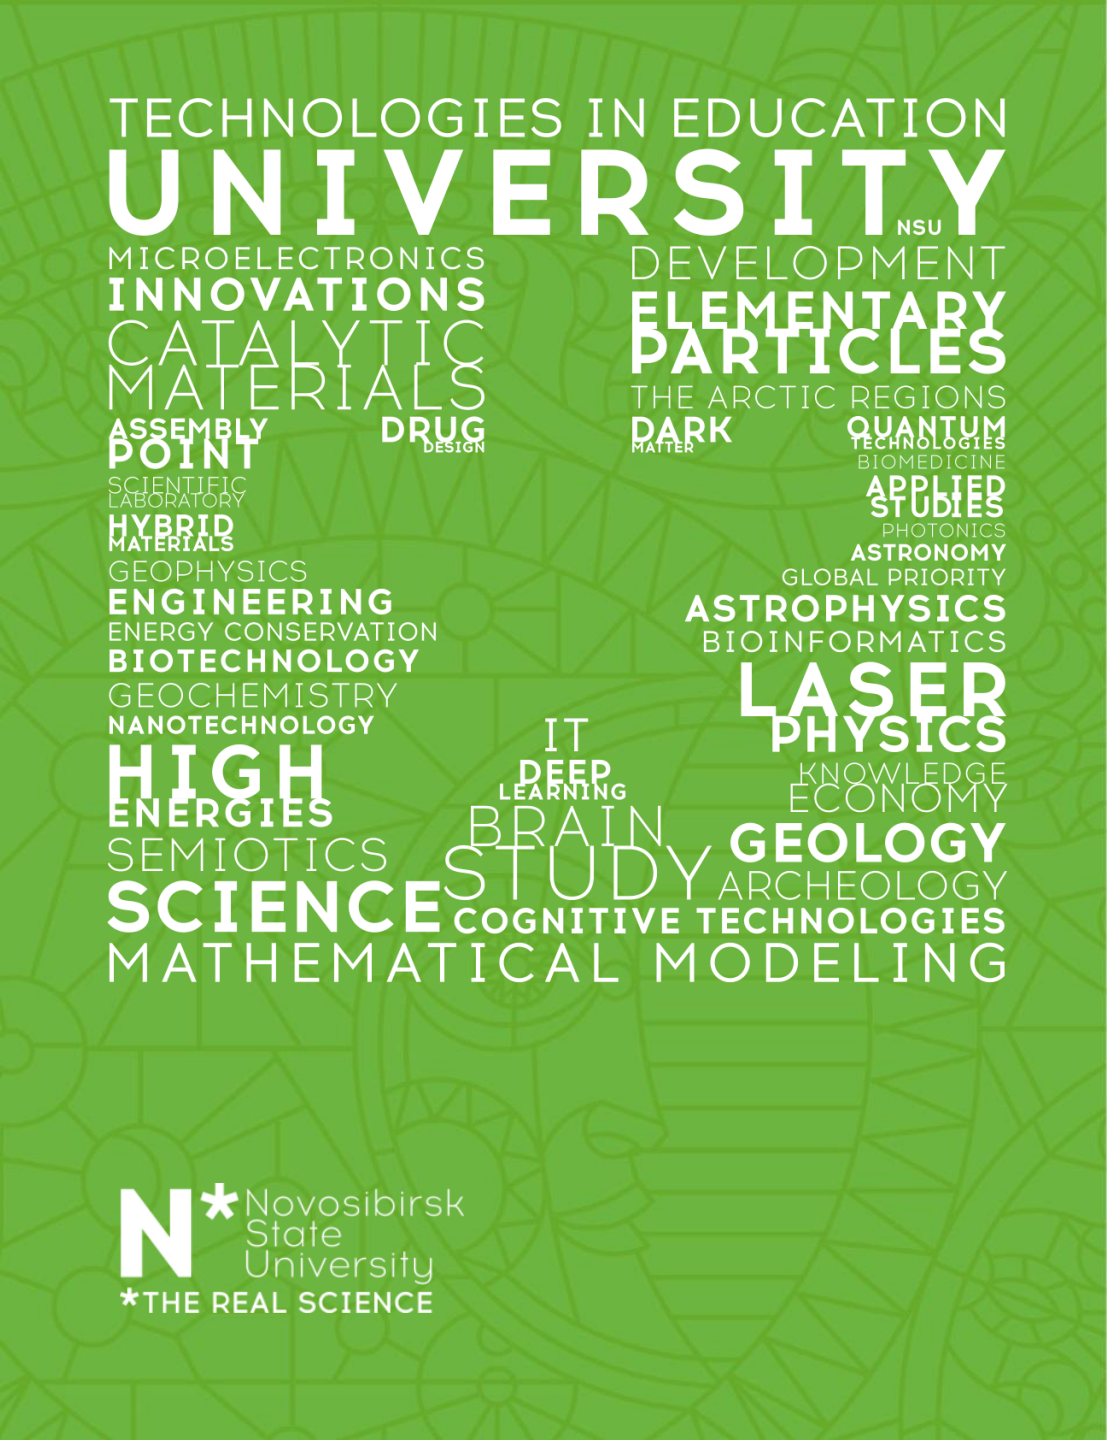

Базовые методы ИИ
Семинар 11

Глушенко Андрей Валерьевич
ФФ НГУ

Практические аспекты

Понижение размерности пространства признаков

t-SNE/UMAP

PCA

Понижение размерности пространства признаков

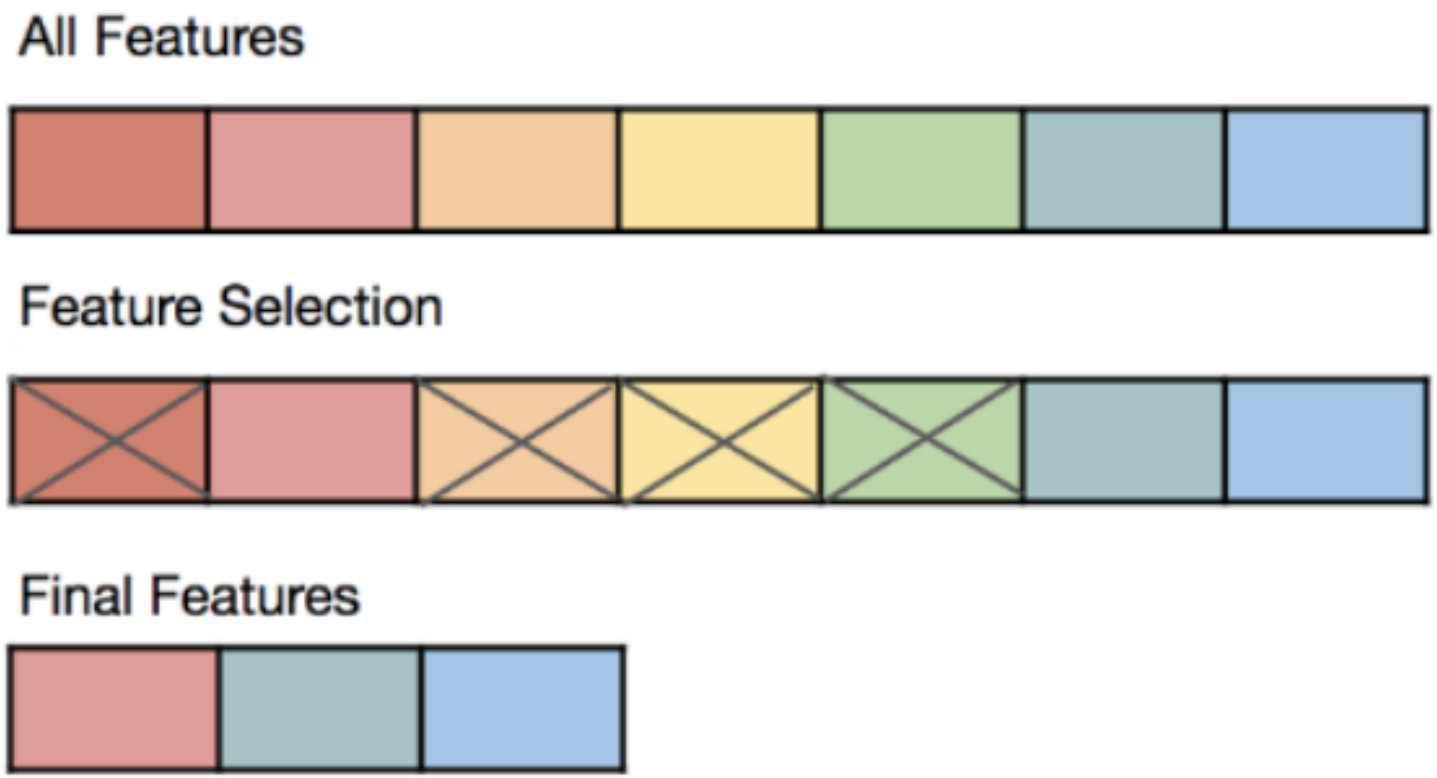

Отбор признаков (Feature Selection)

Здесь мы просто выкидываем лишние столбцы, оставляя оригинальные данные нетронутыми.

- **L1-регуляризация (Lasso):** Добавляя штраф за модуль весов в функции потерь, Lasso буквально «обнуляет» коэффициенты у самых слабых признаков. Если коэффициент стал 0 — признак можно удалять.
- **Статистические фильтры:** Мы считаем корреляцию признаков с целевой переменной или их взаимную корреляцию. Если два признака коррелируют на 0.99, один из них лишний.
- **Жадные алгоритмы (RFE):** Рекурсивное исключение признаков. Обучаем модель, смотрим на важность признаков, выкидываем самый слабый, повторяем до нужного количества.

Извлечение признаков (Feature Extraction)

Здесь создаётся смесь из старых признаков, дающая новые оси. К этой группе относится PCA (с которым мы сегодня познакомимся).

Линейные методы:

- **LDA (Linear Discriminant Analysis):** Похож на PCA, но учитывает «метки» классов. Он ищет такие оси, чтобы точки одного класса были максимально близко, а разных — максимально далеко.
- **ICA (Independent Component Analysis):** Пытается разделить смешанные сигналы на независимые источники (например, выделить голос одного человека из шума толпы).

Извлечение признаков (Feature Extraction)

Нелинейные методы (Manifold Learning):

- **t-SNE и UMAP:** Короли визуализации. Они пытаются сохранить «соседство» точек: если в 100D объекты были похожи, в 2D они тоже будут рядом. Но их сложно использовать для обучения моделей, так как нет обратного преобразования.
- **Autoencoders (Автокодировщики):** Нейросети, которые сжимают данные в узкое «горлышко» (энкодер) и пытаются восстановить их обратно (декодер). Средний слой и есть сжатое признаковое пространство.

Выбор метода

- Если нужно понимать физический смысл каждого признака — используем L1 или RFE.
- Если нужно максимально сжать данные для модели, не теряя информацию — используем PCA или Autoencoders.

Понижение размерности пространства признаков

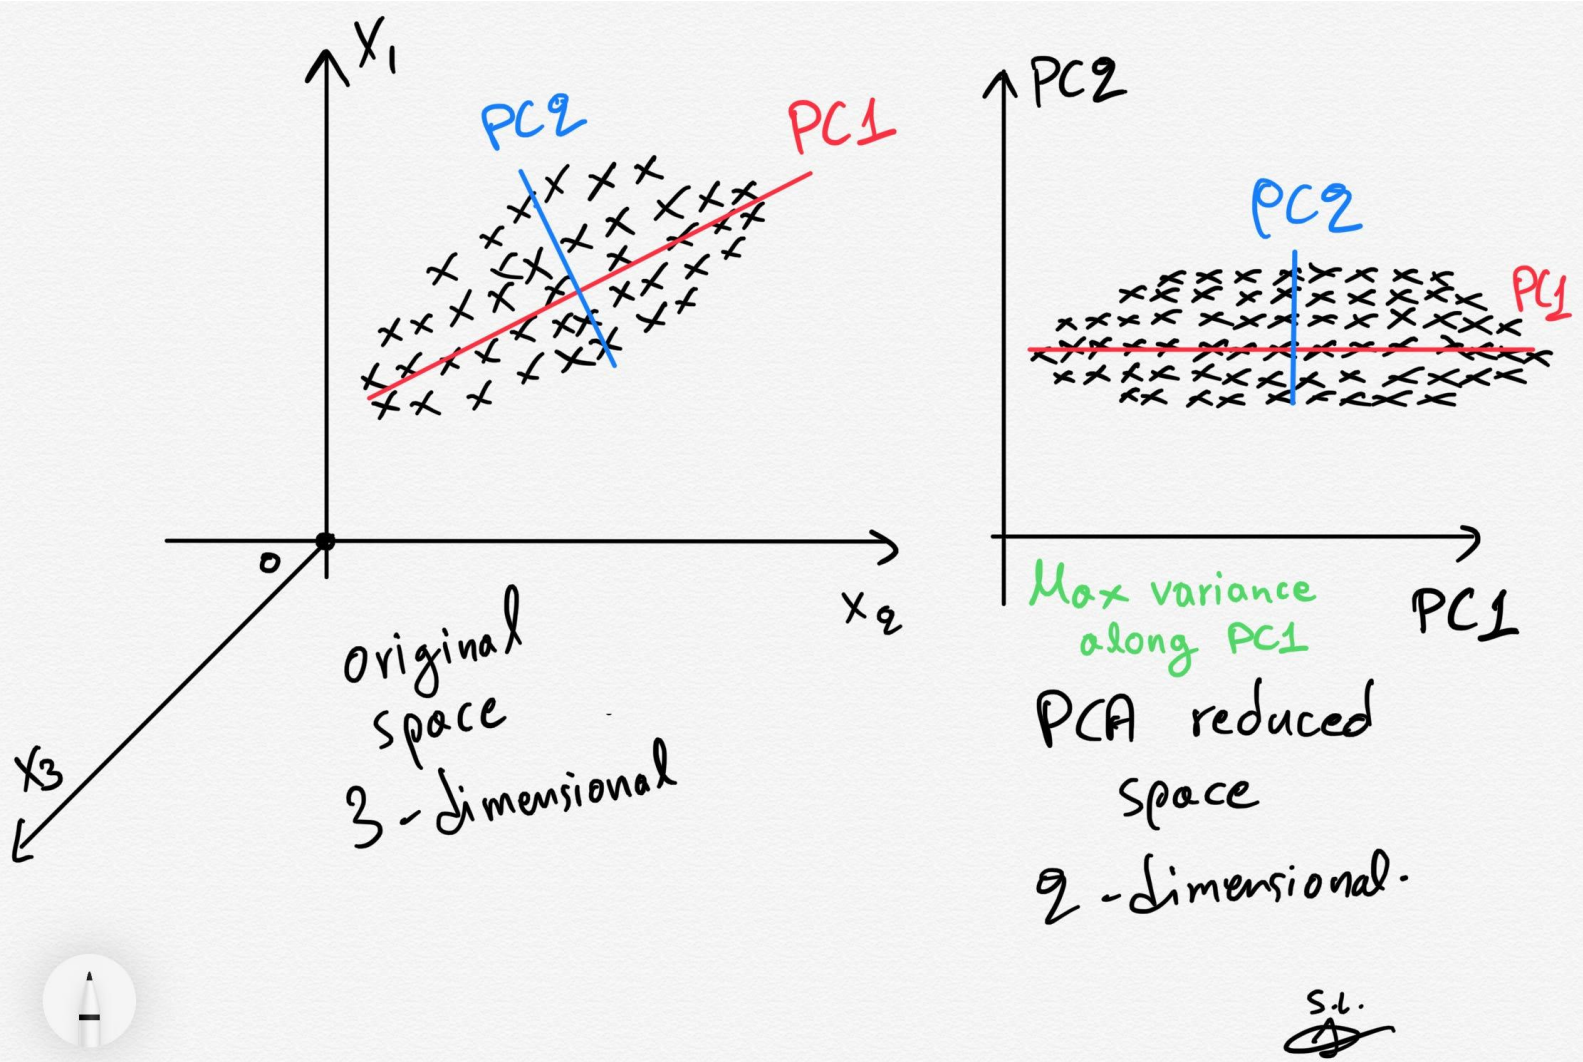

PCA (Principal Component Analysis)

Метод главных компонент (PCA) — это способ упростить данные, сохранив в них самое важное. Представим облако точек: PCA находит такие направления (оси), вдоль которых данные «растянуты» сильнее всего.

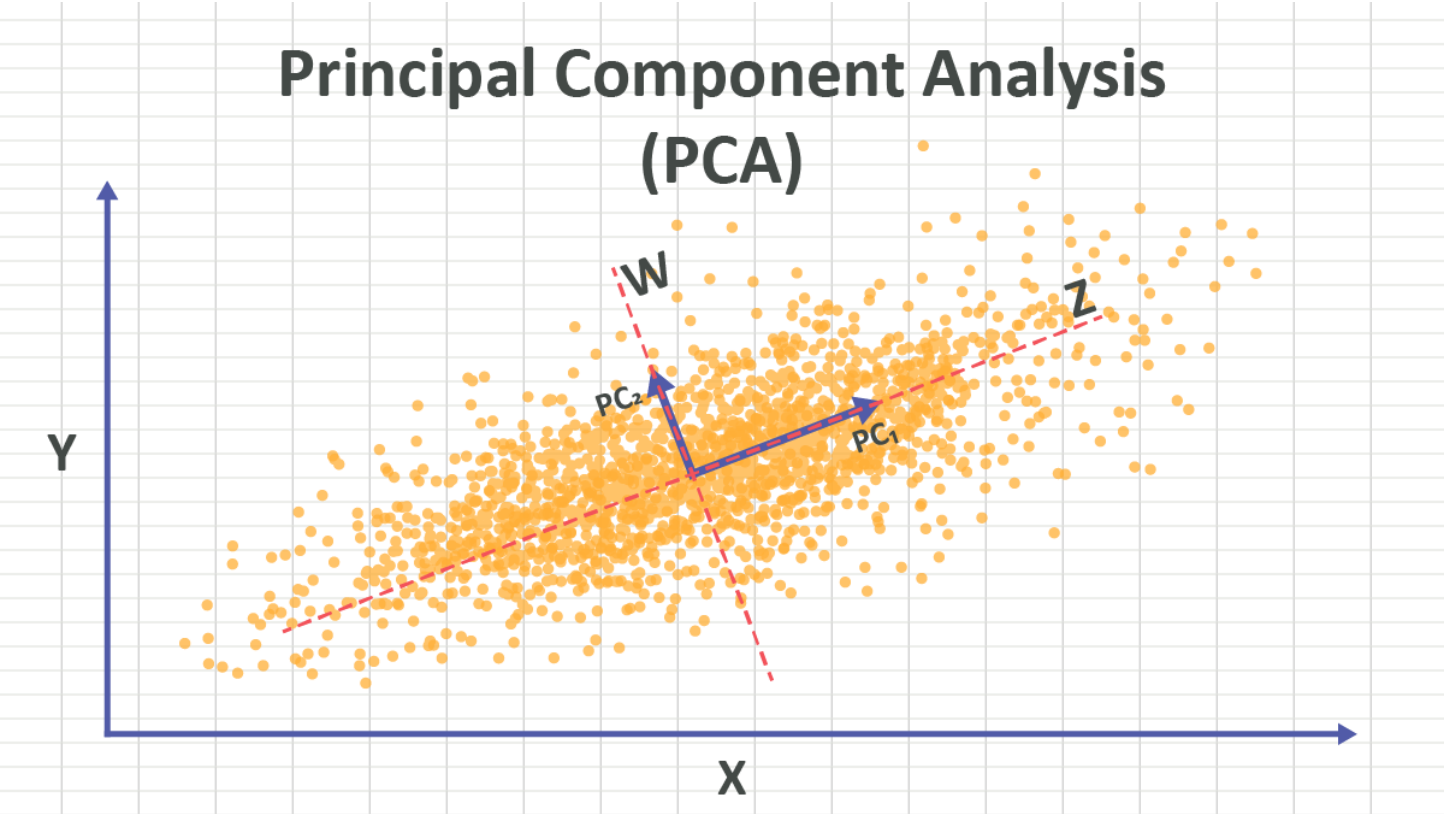

Метод главных компонент (Principal Component Analysis, PCA)

- **Метод главных компонент (Principal Component Analysis, PCA) —** это статистический метод обучения без учителя, используемый для снижения размерности данных с минимальной потерей информации. Он преобразует коррелированные признаки в новые, некоррелированные «главные компоненты», максимизируя дисперсию, что упрощает визуализацию, очищает данные от шума и ускоряет машинное обучение.

Как работает PCA

- **Центрирование:** Мы сдвигаем данные так, чтобы их среднее было в нуле.
- **Поиск направлений:** Первая главная компонента (PC_1) ложится вдоль самого длинного участка данных (максимальная дисперсия). Вторая (PC_2) идет перпендикулярно первой и забирает оставшуюся часть изменчивости.
- **Проекция:** Мы выбрасываем малозначимые компоненты (где данных почти нет) и проецируем точки на оставшиеся оси.
- **Итог:** Было 100 признаков, осталось 3, но они описывают 95% сути.

Связь PCA с SVD (Сингулярным разложением)

- SVD — это «двигатель» под капотом PCA. Если PCA — это концепция того, *что* мы хотим сделать, то SVD — это универсальный алгоритм, который это *вычисляет*.
- Математически PCA чаще всего реализуется именно через SVD. Это более стабильный и быстрый способ, чем работа через матрицу ковариации.
- SVD разлагает любую матрицу $\boldsymbol{X}$ объектов-признаков на три части:

$$\boldsymbol{X} = \boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^{\boldsymbol{T}}$$

Связь PCA с SVD (Сингулярным разложением)

$$\boldsymbol{X} = \boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^{\boldsymbol{T}}$$

- $\boldsymbol{V}$(Правые сингулярные векторы): Это и есть направления наших главных компонент. Они показывают, как старые признаки складываются в новые.
- $\boldsymbol{\Sigma}$(Сингулярные числа): Показывают «силу» каждой компоненты. С их помощью мы понимаем, сколько информации потеряем, если удалим лишние измерения.
- $\boldsymbol{U}\boldsymbol{\Sigma}$: Это координаты ваших данных в новом, сокращенном пространстве.

t-SNE (t-distributed Stochastic Neighbor Embedding)

Главный принцип: «соседи в многомерном пространстве должны остаться соседями на плоскости».

Как это работает: Алгоритм считает вероятность того, что точки являются соседями. Затем он «расталкивает» точки на плоскости так, чтобы похожие оказались рядом, а непохожие — далеко.

Главная фишка: Очень хорошо разделяет данные на четкие кластеры.

t-SNE. Недостатки

- **Медленный** (на больших данных работает долго).
- **Не сохраняет глобальную структуру:** Расстояния между кластерами на графике могут ничего не значить.
- **Результат зависит от Perplexity:** Это параметр «количества соседей», который нужно подбирать вручную.

UMAP (Uniform Manifold Approximation and Projection)

- **Как это работает:** Он строит своего рода «граф» или каркас данных в высоком измерении и пытается максимально точно перенести этот каркас на плоскость.
- **Главная фишка:** Он **быстрее** и лучше сохраняет **глобальную структуру** (то есть не только точки внутри кластера близки, но и сами кластеры располагаются логично относительно друг друга).

UMAP (Uniform Manifold Approximation and Projection). Преимущества

- Работает значительно быстрее t-SNE.
- Масштабируется на очень большие датасеты.
- Позволяет добавлять новые точки в уже построенную проекцию (t-SNE так не умеет).

Обучение без учителя

Постановка задачи кластеризации

K-means, алгоритм кластеризации Ллойда

Алгоритм кластеризации DBSCAN

Задача кластеризации

- **Кластеризация** — это задача машинного обучения «без учителя», когда нужно объединить объекты в группы (кластеры) так, чтобы похожие данные оказались вместе, а разные — как можно дальше друг от друга.
- Главная фишка здесь в том, что нет заранее известных ответов (меток). Алгоритм сам ищет скрытые закономерности в структуре данных.

Постановка задачи кластеризации

- **Входные данные:** У нас есть множество объектов, каждый из которых описан набором признаков (числа, категории).
- **Мера сходства:** Нужно определить, что такое «похожесть». Обычно это расстояние между точками в пространстве (например, евклидово расстояние). Чем меньше расстояние, тем больше сходства.
- **Цель – распределить объекты по группам так, чтобы:**
  - Внутрикластерное сходство было максимальным (точки в одном круге сидят плотно).
  - Межкластерное сходство было минимальным (сами группы стоят далеко друг от друга).

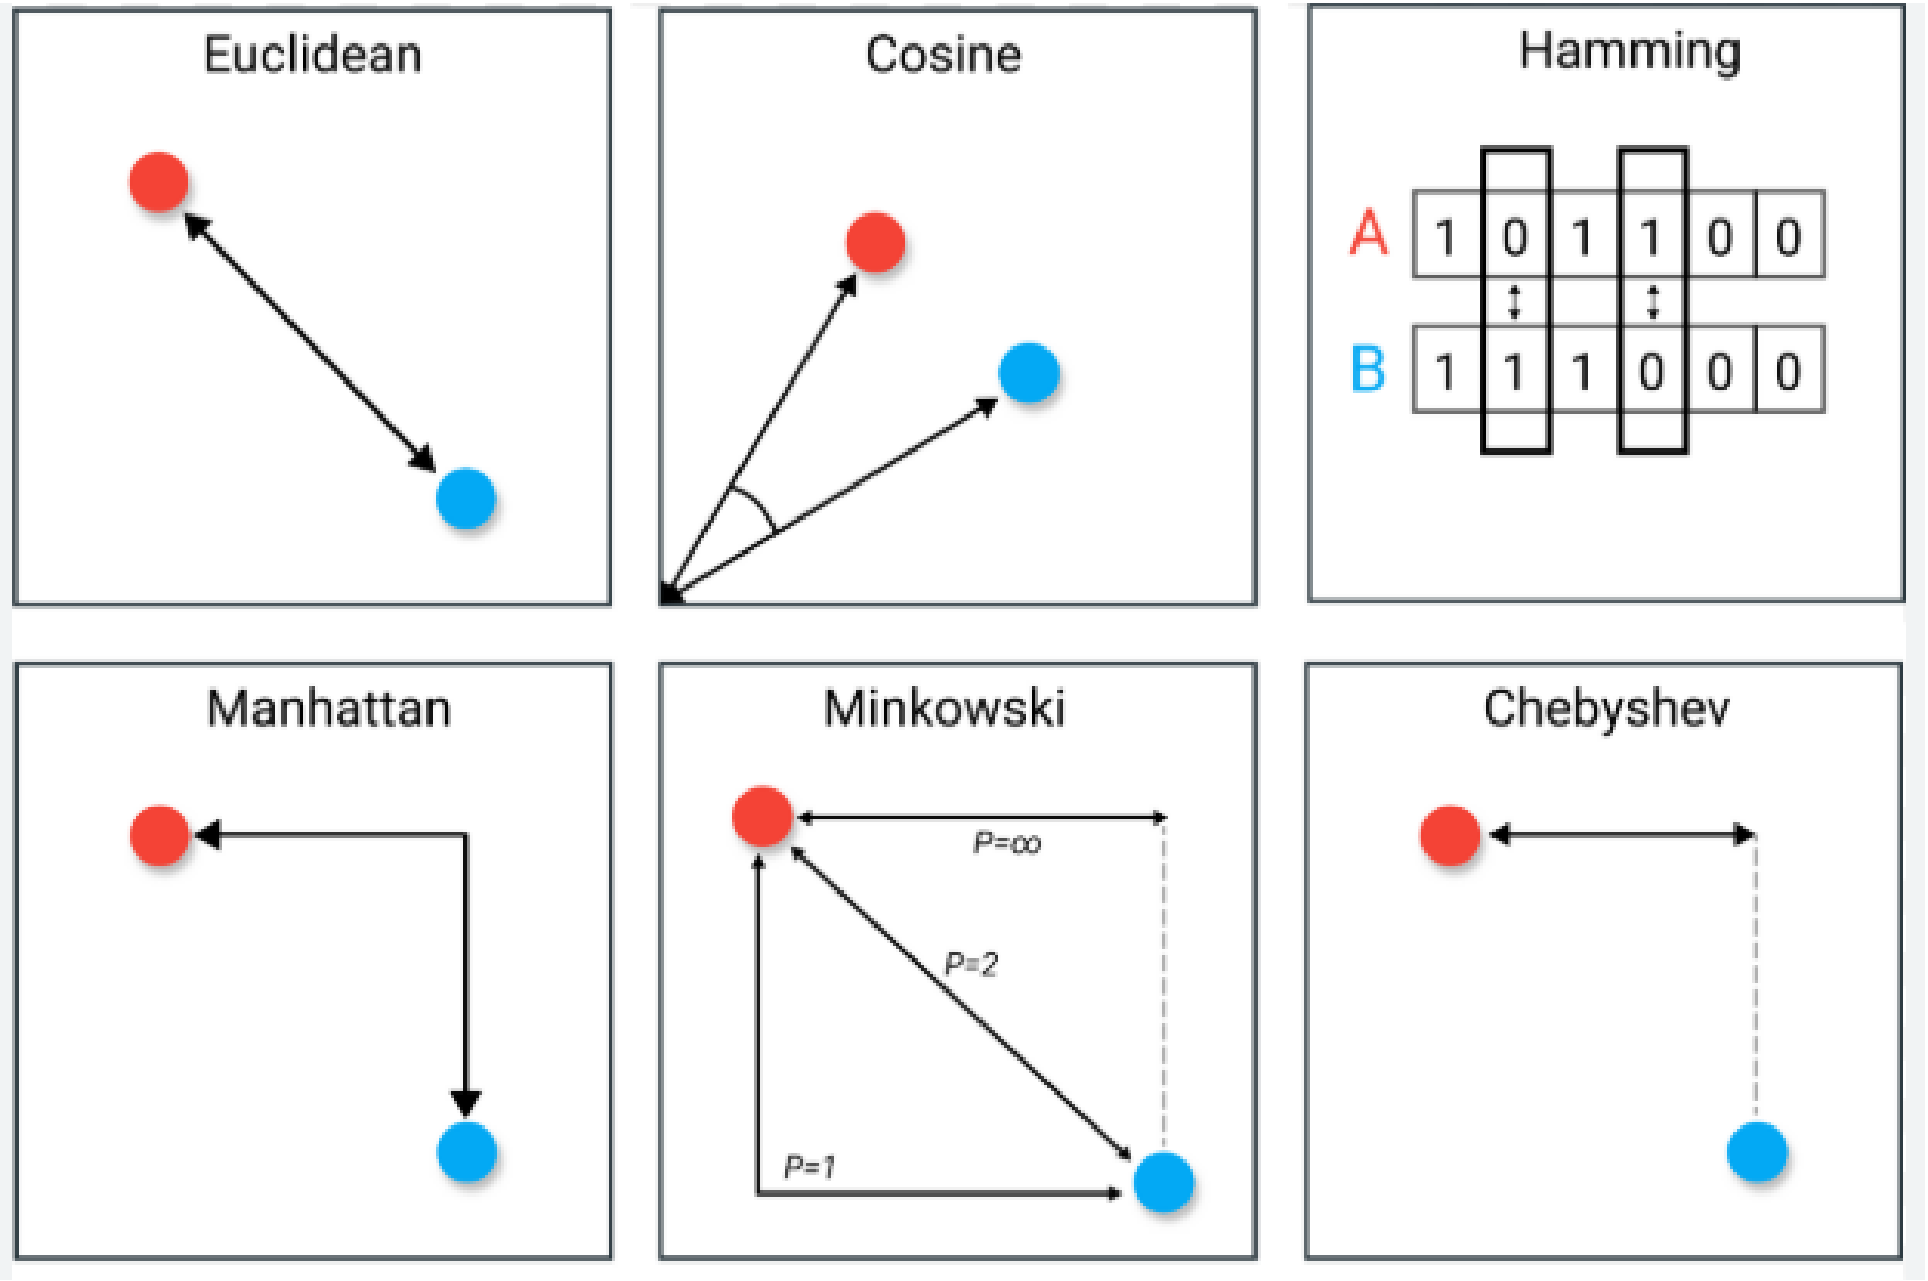
Euclidean
Cosine
Hamming
A
1 0 1 1 0 0
B
1 1 1 0 0 0
Manhattan
Minkowski
P=∞
P=2
P=1
Chebyshev

Применение

- **Сегментация клиентов:** Разбить покупателей на группы по поведению, чтобы делать точные рекламные предложения.
- **Сжатие изображений:** Уменьшить количество цветов, объединив похожие оттенки в один.
- **Анализ текстов:** Группировка новостей по темам без ручного чтения.
- **Биология:** Классификация генов или видов животных по признакам.

Метод k-means

Если говорить глобально, K-means (K-средних) — это итеративный алгоритм, который разбивает данные на k заранее заданных групп. Его главная цель — минимизировать суммарное квадратичное отклонение точек кластера от их центров.

Метод k-means

- **Параметр K:** Это «магическое число», которое мы задаем сами. Алгоритм не знает, сколько групп в данных, он просто выполняет приказ: «Раздели это на k частей».
- **Центроиды:** Это «штаб-квартиры» кластеров. В начале они ставятся случайно, а в конце — оказываются в самом геометрическом центре своей группы точек.
- **Евклидово расстояние:** Самый частый способ измерить близость. Алгоритм просто тянет линейку от точки до всех центроидов и выбирает кратчайший путь.

Алгоритм Ллойда

Алгоритм Ллойда — это классический и самый популярный способ реализации метода K-means (K-средних).

Преимущества:

- **Скорость:** Он работает очень быстро даже на больших объемах данных.
- **Простота:** Его легко понять и запрограммировать.

Алгоритм Ллойда

Недостатки:

- **Рандомизация решает всё:** Если в самом начале поставить центроиды неудачно, алгоритм может застрять в «плохом» варианте. Поэтому часто его запускают несколько раз.
- **Только сферы:** Алгоритм Ллойда хорошо ищет только округлые, выпуклые группы. Если данные лежат «бумерангом» или «змейкой», он их адекватно не разделит.
- **Чувствительность к выбросам:** Одна точка очень далеко в стороне может сильно «утянуть» центр кластера на себя.

Алгоритм Ллойда

1. Инициализация: Выбор числа k (сколько групп хотим получить) и ставим в пространстве данных k случайных точек. Это — начальные центроиды (центры масс будущих кластеров).

2. Шаг привязки (Assignment): Каждый объект из данных «смотрит», какой из центроидов к нему ближе всего (обычно по прямой — Евклидову расстоянию), и примыкает к нему. Так формируются временные кластеры.

3. Шаг обновления (Update): Внутри каждой полученной группы вычисляется «центр тяжести» (среднее арифметическое всех координат точек). Старый центроид прыгает в это новое место.

4. Повторение: Шаги 2 и 3 повторяются снова и снова. Центроиды двигаются, точки меняют владельцев, пока положение центров не стабилизируется (они перестанут двигаться).

Алгоритм DBSCAN

DBSCAN (Density-Based Spatial Clustering of Applications with Noise) расшифровывается как «кластеризация, основанная на плотности». Его главная фишка: он не просит угадывать число кластеров, а сам находит области, где точки сидят «густо».

Алгоритм ищет произвольную ядровую точку и рекурсивно присоединяет к ней все плотностно-достижимые точки, формируя кластер. Если точка не достижима ни из одного ядра, она помечается как шум.

Алгоритм DBSCAN

1. **Основные определения:**

Для набора точек D вводятся следующие понятия:

- **$\boldsymbol{\varepsilon}$-окрестность точки $\boldsymbol{p}$**: Множество точек $N_\varepsilon(p) = \{q \in D | dist(p, q) \leq \varepsilon\}$
- **Ядровая точка:** точка p, у которой количество соседей не меньше заданного порога $|N_\varepsilon(p)| \geq MinPts$
- **Достижимая по плотности точка:** Точка q достижима из p, если p – ядровая точка и $q \in N_\varepsilon(p)$
- **Связность по плотности:** Точки p и q связны, если существует цепочка точек $p_{1,}, p_2, \dots, p_n$, где $p_1 = p, p_n = q$ и каждая последующая точка достижима из предыдущей.

Алгоритм DBSCAN

2. Формализация кластера:

Кластер C в DBSCAN – это непустое подмножество точек, удовлетворяющее двум условиям:

- **Максимальность:** Если $\mathrm{p} \in C$ и q достижима из p по плотности, то $q \in C$
- **Связность:** Все точки внутри кластера C плотно-связны между собой.

Алгоритм DBSCAN

3. Классификация точек:

После работы алгоритма каждая точка попадает в одну из трёх категорий:

- Ядро: внутри плотной области.
- Граничная: входит в окрестность ядра, но сама не имеет достаточно соседей.
- Шум: Точки, не попавшие ни в одну ε-окрестность ядровых точек, т. е. $D \setminus C_i$.

Алгоритм DBSCAN

Шаг 1. Помечаем все точки как непосещенные.

Шаг 2. Выбираем случайную точку p. Если она уже посещена, переходим к следующей.

Шаг 3. Проверяем условие плотности: Находим все точки в $N_\varepsilon(p)$. Если $|N_\varepsilon(p)| < MinPts$, то помечаем p как шум, иначе создаём новый кластер C и включаем в него p.

Шаг 4. Расширяем кластер:

4.1. Добавляем все точки из $N_\varepsilon(p)$ в очередь расширения S.

Алгоритм DBSCAN

4.2. Для каждой точки $q \in S$:

- Если q была помечена как шум, меняем статус на «граничная точка» и добавляем в C.
- Если q не посещена, помечаем как посещенную. Если при этом q – основная точка ($|N_\varepsilon(q)| \geq MinPts$), добавляем все точки из $N_\varepsilon(q)$, в очередь расширения S.
- Добавляем q в кластер C.

Шаг 5. Повторяем, пока не закончатся непосещенные точки в наборе данных.

Алгоритм Ллойда vs DBCSAN

Чтобы наглядно понять разницу, представим, что мы смотрим на карту города сверху:

- **K-means** — это как деление города на административные районы
- **DBSCAN** — это поиск реальных скоплений людей на улицах. Мы не задаём заранее, на сколько скоплений нам нужно разделить, только «правила плотности» (расстояние и минимум соседей). Алгоритм сам скажет: «Я нашел здесь 5 групп, а всё остальное — мусор».

Алгоритм Ллойда vs DBCSAN. Выбросы в данных

- **K-means:** Каждую точку обязан пристроить хоть к какому-то кластеру. Если одна точка улетела «в космос», она всё равно будет числиться в ближайшем кластере и, скорее всего, сильно сместит его центр к себе.
- **DBSCAN:** Очень «придирчивый». Если точка стоит в стороне и у неё нет компании, он пометит её как Noise (шум). Это идеальный способ чистить данные от аномалий.

Алгоритм Ллойда vs DBCSAN. Плотность в данных

- **K-means:** Хорошо работает, даже если плотность в разных группах разная.
- **DBSCAN:** Пасует, если в данных есть «густые» города и «редкие» деревни. Если ты настроишь его на поиск городов, он проигнорирует деревни как шум. Если настроишь на деревни — города сольются в одно огромное пятно.

Практика

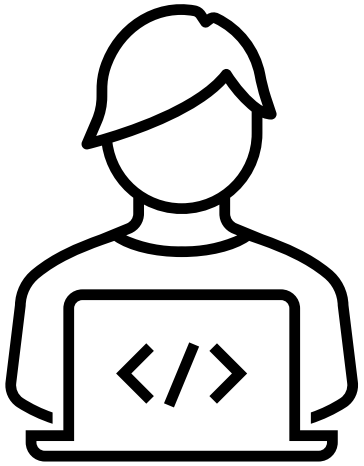

Ресурсы для изучения ML

Лабораторные работы