

Глубокое обучение. Лабораторная работа

преп.: Андрей Глушенко

28 апреля 2026 г.

1 Прямое и обратное распространение

1.1 Логистическая регрессия

Логистическая регрессия — довольно популярный метод в машинном обучении для классификации данных на две категории. Этот метод основан на линейной регрессии, используя ту же линейную модель, но с добавлением сигмоидной функции, которая преобразует выходные данные линейной модели в значение от 0 до 1. Это значение затем можно интерпретировать как вероятность. Обычно это представляется следующим образом:

$$P(y = 1|x_{in}) = x_{out} = \text{sigmoid}(x_{in}) = \frac{1}{1 + e^{-x_{in}}},$$

где x_{in} — это, как следует из названия, это входной скаляр (который также является выходом линейной модели), x_{out} — это скалярное значение на выходе.

Если ошибка, распространяющаяся обратно в x_{out} , это $\frac{\partial E}{\partial x_{out}}$, напомним выражение для $\frac{\partial E}{\partial x_{in}}$ с точки зрения $\frac{\partial E}{\partial x_{out}}$.

$$\begin{aligned} \frac{\partial E}{\partial x_{in}} &= \sigma'_{x_{in}} = \left(\frac{1}{1 + e^{-x_{in}}} \right)' = \frac{0 - 1(1 + e^{-x_{in}})'}{(1 + e^{-x_{in}})^2} = \frac{-(-1)e^{-x_{in}}}{(1 + e^{-x_{in}})^2} = \frac{-1 + 1 + e^{-x_{in}}}{(1 + e^{-x_{in}})^2} = \\ &= \frac{1 + e^{-x_{in}}}{(1 + e^{-x_{in}})^2} - \frac{1}{(1 + e^{-x_{in}})^2} = \frac{1}{1 + e^{-x_{in}}} - \left(\frac{1}{1 + e^{-x_{in}}} \right)^2 = \\ &= \sigma(x_{in}) - \sigma^2(x_{in}) = \sigma(x_{in})(1 - \sigma(x_{in})) \end{aligned}$$

1.2 Многоклассовая логистическая регрессия

Многоклассовая логистическая регрессия — это обобщение логистической регрессии на несколько классов. В основе этого метода лежит выражение softmax. После получения n неограниченных значений выражение softmax нормализует эти значения до n значений, сумма которых равна 1. Затем это можно рассматривать как вероятности, присвоенные различным классам классификатором. Задача здесь — распространить ошибку обратно через этот модуль. Выражение для softmax, которое указывает на вероятность принадлежности к i -му классу:

$$P(y = i|X_{in}) = (X_{out})_i = \frac{e^{-\beta(X_{in})_i}}{\sum_k e^{-\beta(X_{in})_k}}$$

Посчитаем выражение для $\frac{\partial (x_{in})_i}{\partial (x_{out})_j}$ (ответ отличается при $i = j$ и $i \neq j$).

Переменные X_{in} , X_{out} являются не скалярами, а векторами.

В то время как X_{in} представляет собой n значений, поступающих в систему, X_{out} представляет собой n вероятностей, выходящих из системы. Следовательно, выражение $(X_{out})_i$ представляет собой i -й элемент X_{out} .

$$\frac{\partial (X_{out})_i}{\partial (X_{in})_j} = ?$$

Положим:

$$f_i = (X_{out})_i = \frac{e^{-\beta(X_{in})_i}}{\sum_k e^{-\beta(X_{in})_k}}$$

$$f_j = (X_{out})_j = \frac{e^{-\beta(X_{in})_j}}{\sum_k e^{-\beta(X_{in})_k}}$$

$i = j$:

$$\begin{aligned} f'_{(X_{in})_i} &= \frac{(e^{-\beta(X_{in})_i})' \sum_k e^{-\beta(X_{in})_k} - e^{-\beta(X_{in})_i} (\sum_k e^{-\beta(X_{in})_k})'}{(\sum_k e^{-\beta(X_{in})_k})^2} = \\ &= \frac{-(e^{-\beta(X_{in})_i}) \beta'(X_{in})_i \sum_k e^{-\beta(X_{in})_k}}{(\sum_k e^{-\beta(X_{in})_k})^2} - \frac{-(e^{-\beta(X_{in})_i})^2 \beta'(X_{in})_i}{(\sum_k e^{-\beta(X_{in})_k})^2} = \\ &= -\beta'(X_{in})_i \left(\frac{e^{-\beta(X_{in})_i}}{\sum_k e^{-\beta(X_{in})_k}} + \left(\frac{e^{-\beta(X_{in})_i}}{\sum_k e^{-\beta(X_{in})_k}} \right)^2 \right) = \beta'(X_{in})_i (f_i(f_i - 1)) \end{aligned}$$

$i \neq j$:

$$\begin{aligned} f'_{(X_{in})_j} &= \frac{(e^{-\beta(X_{in})_i})'_{(X_{in})_j} \sum_k e^{-\beta(X_{in})_k} - e^{-\beta(X_{in})_i} (\sum_k e^{-\beta(X_{in})_k})'_{(X_{in})_j}}{(\sum_k e^{-\beta(X_{in})_k})^2} = \\ &= \frac{-(e^{-\beta(X_{in})_i}) (e^{-\beta(X_{in})_j}) \beta'(X_{in})_j}{(\sum_k e^{-\beta(X_{in})_k})^2} = -\beta'(X_{in})_j f_i f_j \end{aligned}$$

1.3 Задача. Простая нейронная сеть




Рис. 1: Простая нейронная сеть

На рисунке 1 представлена простая нейронная сеть с входными сигналами x_1 и x_2 (оба скалярные). Оба входа проходят через описанный выше сигмоидный слой. Затем выходные сигналы

с сигмоидного слоя проходят через слои $\max$ и $\min$, выходные сигналы которых можно представить как $o_{\min} = \min(i_1, i_2)$ и $o_{\max} = \max(i_1, i_2)$. Значения, полученные слоями $\min$ и $\max$, затем суммируются в последнем слое.

Предположим, что ошибка, передаваемая (обратно распространяемая) на y , равна $\frac{\partial E}{\partial y}$. Запишите значения $\frac{\partial E}{\partial x_1}$ и $\frac{\partial E}{\partial x_2}$ через $\frac{\partial E}{\partial y}$.

Оформить вычисления в виде .pdf с помощью LaTeX.